Fundamental State Space Time Series Models for JEPX Electricity Prices

Kenta Ofuji Member (CRIEPI/University of Aizu, ko-ofuji@criepi.denken.or.jp)
Shigeru Kanemoto Non-member (University of Aizu, kanemoto@u-aizu.ac.jp)

Keywords: Japan Electric Power Exchange, wholesale electricity price behavior, non-stationarity, state space models, price forecasting

1. Introduction

Electricity price modelling is one of the key risk management tools in the age of deregulation of the electric power industry, with its main aim being price forecasting to aid corporate decision making for power producers and utility companies. Since it started operation in April 2006, Japan's wholesale electric power trading market, Japan Electric Power Exchange (JEPX), has seen a constant increase in its trading volume. We attempted to analyse the market price dynamics of the exchange over a one and a half year horizon, using state space (SS) models, comparing them with ordinary least-square (OLS) time-series models to capture non-stationarity and underlying structural changes in the market, and to forecast prices.

2. The Market and the data

JEPX offers two standard exchange markets: the Day-Ahead Spot and Standard Forward markets, and the Bulletin Board market to facilitate tailor-made deals among participants. The Day-Ahead Spot market trades forty-eight 30-minute power commodity strips at the single-price auction market. We used the Spot market open price data available to the public on their website (www.jepx.org).

3. The Models

Power prices dynamics, as well as those of other financial commodities, are thought to follow non-stationary time series, with its average level and autocovariance function changing over time. In this paper, we used two state space (SS) models, to capture (i) such non-stationarity, and (ii) potential structural changes underlying the market.

Our SS models are based on the following expressions:

$$x_n = F_n x_{n-1} + G Q_n$$
$$y_n = H_n x_n + R_n$$

where x_n: state to be estimated, y_n: observed prices, F: state transition matrix, G: noise gain, Q_n: system noise, H_n: observation matrix, and R_n: observation noise. All state variables change step-by-step in a calculation based on the previous step information on the Kalman Filter algorithm. For the above purposes, (i)and (ii), we applied the following assumptions:

(i) SS Model 1: Price series to be decomposed to a stochastic trend factor and an auto-regressive (AR) factor

(ii) SS Model 2: Explanatory variable coefficients to change over time, following AR(1), to reflect changes in the underlying market dynamics.

Both models were optimized based on log-likelihood maximization and AIC (Akaike Information Criteria) minimization. Further, we evaluated the price forecasting capabilities, comparing with standard OLS models employing ARCH terms to accommodate heteroscedasticity.

4. Results and Discussion

Our SS Model 1 was able to extract non-stationary stochastic trends as shown in Fig. 1, with a trend following the 1st order derivative and the rest following an AR(2) process. The price level of a typical on-peak commodity 15:00–15:30 is, on average, around 10 yen/kWh level over the estimation horizon, within which an AR process exists, ranging approximately between +/−2 yen. Our SS Model 2 was able to capture changes on coefficients of explanatory variables moving around its mean, and future price forecast results over 10 periods showed as good a forecasting accuracy as AR and ARCH models. However, the forecasting error tended to grow quicker than the AR and ARCH model, indicating room for further optimization and enhancement.

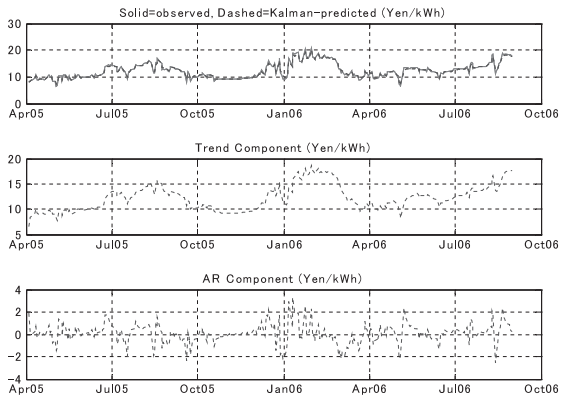

Fig. 1. JEPX spot market 15:00–15:30 price series decomposed to stochastic non-stationary trend factor and auto-regressive factor

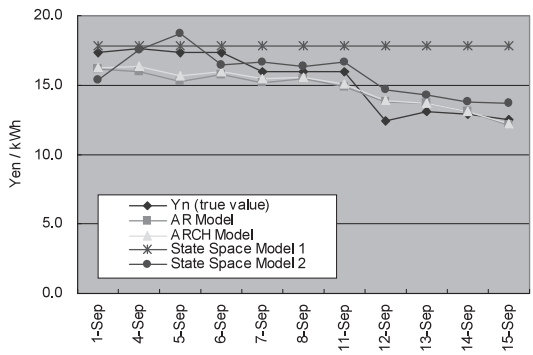

Fig. 2. Price forecast example by AR, ARCH and State Space models

論　文

状態空間モデルを用いたJEPX価格モデリングの基礎検討

正　員　大藤　建太[*,**]　非会員　兼本　　茂[**]

Fundamental State Space Time Series Models for JEPX Electricity Prices

Kenta Ofuji[*,**], Member, Shigeru Kanemoto[**], Non-member

Time series models are popular in attempts to model and forecast price dynamics in various markets. In this paper, we have formulated two state space models and tested them for its applicability to power price modeling and forecasting using JEPX (Japan Electric Power eXchange) data. The state space models generally have a high degree of flexibility with its time-dependent state transition matrix and system equation configurations. Based on empirical data analysis and past literatures, we used calculation assumptions to a) extract stochastic trend component to capture non-stationarity, and b) detect structural changes underlying in the market. The stepwise calculation algorithm followed that of Kalman Filter. We then evaluated the two models' forecasting capabilities, in comparison with ordinary AR (autoregressive) and ARCH (autoregressive conditional heteroskedasticity) models. By choosing proper explanatory variables, the latter state space model yielded as good a forecasting capability as that of the AR and the ARCH models for a short forecasting horizon.

キーワード：日本卸電力取引所，卸電力価格挙動，非定常性，状態空間モデル，価格予測
Keywords: Japan Electric Power Exchange, wholesale electricity price behavior, non-stationarity, state space models, price forecasting

1. 背景と目的

2005年4月より日本卸電力取引所（Japan Electric Power eXchange：JEPX）での卸電力取引が開始され注目を集めている。開設2年目でまだ十分とはいえないものの，最近ではある程度取引実績データの蓄積も進んできた。同所における取引量は，2005年度の実績では文献(1)にも言われているようにまだ本邦電力需要全体の0.1%前後のオーダである。しかしながら取引量は順調な伸びを続けており，2006年9月の月間約定総量で見ると前年同時期比約60%以上増加していて，季節による上下はあるものの今後とも拡大が予想され，同市場における価格動向等について一定の知見を得ておくことは重要である。

卸電力市場価格はいわゆる価格スパイクなど特有の振舞いに注目が集まるところである。価格モデルアプローチには大別して，背後の実需給をそれほど考慮せずに価格挙動を数列とみなしてそれをよく再現する金融工学時系列モデルを構成するもの[(2)]と，売買入札量といった市場需給や，背後にある電力需給状況を考慮しそれらの影響度の実証的分析から価格を導出しようとするものとがある[(3)]が，実務的観点からはやはり需給事情との関連をある程度示唆するようなモデルが待たれているのではないかと考えられる。いずれの場合も工夫を要する点の一つは，価格に影響を与える実需給要因の影響度を納得感ある形で反映しつつも，トレンドなどの非定常的・確率的な振舞いを実態に即して考慮することであろう。例えば，伊藤ほか（2007）[(4)]は米国PJM一日前市場データに関してデータの適切な前処理による確定的要因の分離と，確率的部分へのGARCHモデルの採用によってこれを解決している。この例に限らず，定常性を前提とするいわゆる計量経済モデルでは非定常部分の抽出やその先験的仮定の巧拙がモデルの精度に大きな影響を与えると考えられる。

本稿ではこれに対し，状態空間モデルを用いて非定常要素に関する先験的仮定なしに抽出を行ったうえで，赤池情報量規準（Akaike Information Criteria：AIC）による客観的次数選択をへて時系列の要素分解を実現するKitagawa and Gersch（1985）[(5)]の考え方を参考とし，JEPX価格系列への適用を試みた。また，本状態空間モデルを用いて価格予測を行い，別途構成した最小2乗法の代表的なモデル（ARお

[*]（財）電力中央研究所 社会経済研究所
〒201-8511　狛江市岩戸北 2-11-1
Socio-Economic Research Center, CRIEPI
2-11-1, Iwado Kita, Komae 201-8511
[**] 会津大学
〒965-8580　会津若松市一箕町
University of Aizu
Ikki-machi, Aizu-Wakamatsu 965-8580

© 2008 The Institute of Electrical Engineers of Japan.

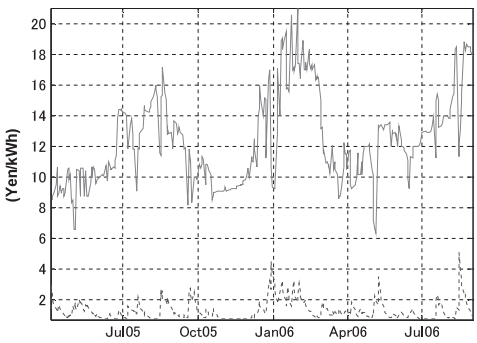

図 1　JEPX 一日前スポット市場 15:00–15:30 銘柄の価格パス（実線）と推定された変動ボラティリティ（標準偏差，破線）

Fig. 1.　Price and estimated volatility paths of 15:00–15:30 strip, JEPX day-ahead market.

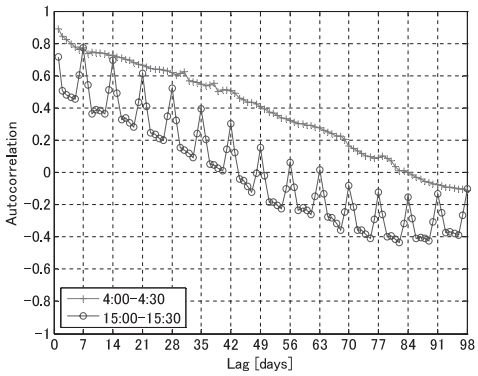

図 2　ピーク，オフピーク銘柄価格の自己相関

Fig. 2.　Autocorrelation of price levels of selected price strips.

よび ARCH モデル）と，その予測パフォーマンスに関して比較を行った。

〈1･1〉 JEPX 価格系列の非定常性とその取扱い　前節でも触れたが時系列モデルとして代表的な最小二乗法ではモデルの構造が推定期間を通じて変化しない，という前提がある。このため最小二乗法のモデルには定常性が要求され，それにあてはまらない非定常部分は (G)ARCH 項などの考慮によって吸収される。図 1 には例として，JEPX スポット市場ピーク時間帯銘柄の一つである 15:00–15:30 銘柄の価格と推定された変動ボラティリティ（標準偏差）パスを示すが，時間依存の平均と分散を有する非定常性が明確に見られる。また図 2 には同じデータの標本自己相関係数をオフピーク 4:00–4:30 銘柄のそれと比較して示したが，週周期性の強さの違いはあるものの，ピーク・オフピーク銘柄ともに自己相関が急速にゼロにならず強い系列相関を有することなどからその長期記憶性が明確に見て取れる。

ところで，非定常性は週や季節などの確定周期的なもののほかに，確率的トレンドや時変係数を考慮することによっても表現できる。実際，後出の最小 2 乗法モデルでは確定的周期性を階差処理によって取り除いた後に，それでもなお残る非定常部分を処理するため，時間比例など適当な関数形や多項式を仮定したトレンド項を入れ込むことが一般的である。こうした関数形は定式化の容易性などから恣意的な仮定で選ばれることもあり，あてはまりが必ずしもよくなるとはいえないことと，期間全体にわたる平均的構造としてしか考慮できないという問題がある。またそれ以外の説明変数の係数にしても，定常性を前提として期間全体にわたる平均的な値を与えるに過ぎない。しかし，図 1 を見ると取引構造は時間を追って変化しており，また電力需要の不確定変動や市場参加者行動の変化の影響など，計量モデルの言葉でいえば短期的構造変化も内在しているように思われる。このような場合最小 2 乗法ではダミー変数を用いることによりそうした短期的時変性の捕捉が試みられるが，影響要因が事前に明示的にわかっていないとモデルに組み入れられないこと，またその影響要因がモデルに統計的な確度をもたらすまで繰り返されなければならないことなどの制約も存在する。このように，特に JEPX のような開所間もないエマージングマーケットについては，確定周期的要因のほかにこうした要因も考慮できることは有用である。

このような確率的時変的な影響をとらえるには，一手法として説明変数の時変パラメータを考慮できるモデルが有用であると思われる。実際，マクロ経済分析の分野などでも，時変状態を考慮できる状態空間モデルを用いて労働分配率や全要素生産性などの経時的で連続的な係数変化を捉えようとする検討が行われている [6]。

本稿の構成は次のとおりである。今回はこうした非定常性の捕捉を考慮できると考えられる状態空間モデルを用いて，次章で説明する 2 種類のモデルを作成し，それらを同市場価格データについて適用し，これらの目的が果たされるかどうか検討する。また，通常の最小 2 乗法モデルと係数水準や予測力について比較する。最後に，各モデルについて予測力向上のための方策について検討する。

2. データ

データソースは次のとおりである。価格データについては JEPX ウェブサイト [7] 上の一日前スポット市場公開データのうち，ピーク銘柄と見なせる 15:00–15:30 銘柄の 2005 年 4 月～2006 年 9 月分毎日 30 分毎の取引価格と約定量データを用いた。モデルの推定に 2005 年 4 月～2006 年 8 月期間データを，予測に 2006 年 9 月のデータを用いた。電力需要（流通対応需要）については電気新聞掲載の東京地域の日次情報，気温については気象庁ウェブサイトの東京大手町のデータによった。

今回は確定的変動については対象外なので，電力需要に連動して見られる価格の週末効果を除去するため機械的に土日を除去して週日データのみとした。一方，土日以外の祝日や正月，お盆，黄金連休など，通例電力需要の減る特異期間については，その前後の変動についても考察するため，あえて今回は除去を行わなかった。

3. JEPX 価格状態空間モデルの構成

〈3･1〉 状態空間モデルとカルマンフィルタ ここでは，状態ベクトル x_n，観測値ベクトル y_n に関する下記 (1)，(2) 式で表される状態空間モデルを考える。

$$x_n = F_n x_{n-1} + GQ_n \cdots\cdots (1)$$

$$y_n = H_n x_n + R_n \cdots\cdots (2)$$

(1) 式を状態方程式，(2) 式を観測方程式と呼び，F_n：状態遷移行列，H_n：観測行列，G：状態ノイズゲイン，Q_n：状態ノイズ，R_n：観測ノイズである。状態 x_n としては非観測の値を想定することもあるが，今回は価格系列およびその説明変数群を状態変数とみなす。

時刻 $n-1$ から n となって新しい観測値 y_n が入手される毎に，下記のカルマンフィルタの標準的手順に沿って状態 $x_{n|n-1}$ を $x_{n|n}$ に更新し，ここから一期先予測により予測値 $y_{n|n}$ を逐次的に入手する。それぞれのアルゴリズムは下記である。

［フィルタ］

$$\left.\begin{aligned} K_n &= S_{n|n-1}H_n^T(H_nS_{n|n-1}H_n^T + R_n)^{-1} \\ x_{n|n} &= x_{n|n-1} + K_n(y_n - H_nx_{n|n-1}) \\ S_{n|n} &= (I - K_nH_n)S_{n|n-1} \end{aligned}\right\} \cdots\cdots (3)$$

［一期先予測］

$$\left.\begin{aligned} x_{n|n-1} &= F_nx_{n-1|n-1} \\ S_{n|n-1} &= F_nS_{n-1|n-1}F_n^T + G_nQ_nG_n^T \end{aligned}\right\} \cdots\cdots (4)$$

K_n はカルマンゲイン（Kalman Gain），S_n は x_n の分散共分散，I は単位行列，上添え字 T は行列の転置を示す。

〈3･2〉 モデルの構成・推定 今回は非定常確率的トレンドの分離と，係数の時変性を許すという 2 つの観点からそれぞれ次のように 2 種類の状態空間モデルを検討する。

① モデル 1 非定常トレンド分離モデル

文献 (5) 等にならい，価格系列が非定常な確率的トレンドを内在させながら循環変動すると仮定すると，時刻 n における価格 P_n はトレンドを Tr_n，循環変動を V_n，ノイズを ε_n として，

$$P_n = Tr_n + V_n + \varepsilon_n \cdots\cdots (5)$$

と書ける。トレンドは，Δ を $\Delta t_n = t_n - t_{n-1}$ で表される時間差分オペレータとするとき k 回の差分でゼロになる（$\Delta^k t_n = 0$）ような滑らかな確率過程に従い変動するものとする。例えば $k = 2$ のときは，ノイズを W_{1n} として次のように書ける。

$$Tr_n = 2Tr_{n-1} - Tr_{n-2} + W_{1n} \cdots\cdots (6)$$

また，循環変動 V_n はノイズを W_{2n} として l 次の自己回帰モデル

$$V_n = \sum_{i=1}^{l} \alpha_i V_{n-1} + W_{2n} \cdots\cdots (7)$$

に従うものと仮定する。これらから P_n は

$$\left.\begin{aligned} x_n &= F_{x_{n-1}} + GW_n \\ P_n &= Hx_n + \varepsilon_n \end{aligned}\right\} \cdots\cdots (8)$$

として (1)，(2) 式と同じ形で表せる。ここに $W_n = (W_{1n}, W_{2n})^T$ で，W_{1n}，W_{2n}，ε_t は期待値がゼロ，分散がそれぞれ τ_1^2，τ_2^2，σ_ε^2 で互いに独立な正規乱数である。

例として $k = 2$，$l = 1$ のとき次のような状態空間モデルとなる。

$$\begin{bmatrix} Tr_n \\ Tr_{n-1} \\ V_n \end{bmatrix} = \begin{bmatrix} 2 & -1 & 0 \\ 1 & 0 & 0 \\ 0 & 0 & \alpha_1 \end{bmatrix} \begin{bmatrix} Tr_{n-1} \\ Tr_{n-2} \\ V_{n-1} \end{bmatrix} + \begin{bmatrix} 1 & 0 \\ 0 & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} W_{1n} \\ W_{2n} \end{bmatrix} \cdots\cdots (9)$$

$$y_n = \begin{bmatrix} 1 & 0 & 1 \end{bmatrix} x_n + \varepsilon_n$$

モデルパラメータ $\theta_1 = \{\tau_1, \tau_2, \sigma_\varepsilon, \alpha_i\ (i = 1, \ldots, l)\}$ は最尤法により推定する。k，l の最適な値は AIC 最小化を基準にして決定する。対数尤度 LLH および AIC はそれぞれ次式で与えられる。

$$LLH = -\frac{N}{2}\log 2\pi - \sum_{n=1}^{N}\log r_{1n} - \frac{1}{2}\sum_{n=1}^{N}\frac{(P_n - Hx_{n|n-1})^2}{r_{1n}} \cdots\cdots (10)$$

$$AIC = -2LLH + 2(\theta_1 \text{の次元}) \cdots\cdots (11)$$

ここに，$r_{1n} = HS_{n|n-1}H^T + \sigma_\varepsilon^2$ である。

② モデル 2 時変係数モデル

いま通常の最小二乗モデルのごとく，価格 P_n が 1 次自己回帰項と説明変数 $U_{i,n}$ の線形和として次のように書けるとする。

$$P_n = c + \sum_{i=1}^{I} B_{i,n} \cdot U_{i,n} + AR^P \cdot P_{n-1} + \xi_n \cdots\cdots (12)$$

ただし，c：定数項，$B_{i,n}$：時刻 n における U_i の係数，AR^P：P_n の 1 次自己回帰係数，ξ_n：ノイズ（$\sim N(0, \sigma_\xi^2)$），I：説明変数の総数，$i = 1, \ldots, I$ である。

ここで，$U_{i,n}$ の係数を時変とするため，文献 (8) 等を参考とし $B_{i,n}$ が

$$B_{i,n} = AR_i^B \cdot B_{i,n-1} + \nu_{i,n}^B \cdots\cdots (13)$$

で表される 1 次自己回帰モデルに従ってなめらかに推移するものと仮定する。ここで $\nu_{i,n}^B \sim N(0, \sigma_{Bi}^2)$ である。例として $I = 5$ の場合，これらを反映すると (1)，(2) 式はそれぞれ次のように表される。

$$x_n = \begin{bmatrix} P_n & B_{1,n} & B_{2,n} & B_{3,n} & B_{4,n} & B_{5,n} \end{bmatrix}^T$$

$$\begin{bmatrix} P_n \\ B_{1,n} \\ B_{2,n} \\ B_{3,n} \\ B_{4,n} \\ B_{5,n} \end{bmatrix} = \begin{bmatrix} AR^P & U_{1,n} & U_{2,n} & U_{3,n} & U_{4,n} & U_{5,n} \\ 0 & AR_1^B & 0 & \cdot & \cdot & 0 \\ \cdot & \cdot & AR_2^B & \cdot & & \cdot \\ \cdot & & \cdot & AR_3^B & \cdot & \cdot \\ \cdot & & & \cdot & AR_4^B & 0 \\ 0 & \cdot & \cdot & \cdot & 0 & AR_5^B \end{bmatrix} \begin{bmatrix} P_{n-1} \\ B_{1,n-1} \\ B_{2,n-1} \\ B_{3,n-1} \\ B_{4,n-1} \\ B_{5,n-1} \end{bmatrix}$$

$$+\begin{bmatrix}\xi_n & \nu^B_{1,n} & \nu^B_{2,n} & \nu^B_{3,n} & \nu^B_{4,n} & \nu^B_{5,n}\end{bmatrix}^T$$

$$y_n = \begin{bmatrix}1 & 0 & 0 & 0 & 0 & 0\end{bmatrix} x_n + w_n \cdots\cdots\cdots\cdots (14)$$

ここに $w_n \sim N(0, \sigma_w^2)$ とする。

今回は，後に最小 2 乗法モデル（補論を参照）との比較と行うことから説明変数群としては表 6 と同じものを用い $I = 5$ とする。モデルのパラメータは，(10) 式において r_{1n} の代りに $r_{2n} = HS_{n|n-1}H^T + \sigma_w^2$，$\theta_1$ の代りに $\theta_2 = \{\sigma_\xi, \sigma_{Bi}\ (i = 1, \ldots, 5)\}$ として最尤法により推定し，$AR^B_{1\sim5}$ については簡単のため $AR^B_1 = \ldots = AR^B_5 = AR^B$ とし，やはり対数尤度（Log Likelihood：LLH）を最大化するような AR^B を選択する。

4. 結果と考察

〈4･1〉 状態空間モデルのチェック　構成した状態空間モデルが，所期のトレンド抽出と係数推定を行えるかどうかの事前チェックとして，人為的に生成したデータを用いてモデル自体が妥当かどうかを下記の要領でチェックした。

① モデル 1　非定常トレンド分離と AR 係数推定が適当に行われるか確認するため，(5) 式において非定常トレンド $Tr_n = 1 - \exp(n/100)$，2 次の AR 循環変動 $V_n = 0.9P_{n-1} - 0.4P_{n-2}(+0P_{n-3})$，$\sigma_n = 0.1$ としたデータを人為的に生成し，モデル①に入力した。結果を図 3 と表 1 に示すが，波形，係数ともおおむね良好な推定が行われているのが確認でき，非定常トレンドに関しても良好に抽出しているのが見て取れる。なお表 1 中，各ノイズ W_{1n}，W_{2n}，ε_n は仕上がりの観測系列においては足しあわされた形で得られるので，原系列でこれらは一つの変数にまとめて与えている。

② モデル 2　時変係数推定が行われるか確認するため，(12)，(13) 式において $c = 0$，$I = 1$，$AR^B_1 = 0.9$，$P_0 = B_{1,0} = 0$，σ_ξ と σ_w をまとめて 0.1，また $U_{1,n}$ として前述の東京地区流通対応需要データに種々の既知パラメータ AR^P，σ_{B1} を与えて人為的に生成したデータをモデル②に入力した。推定結果を図 4 および表 2 に示す。これらをみると，モデル②についても波形，係数ともおおむね良好な推定が行われていることが確認できた。図 4 には表 2 における Case II の場合について得られた波形を示した。Case I～III 以外の設定値についても種々試したが，一般的な傾向として AR 係数 AR^P が高くなるほどフィッティングの傾向は良好となり，逆に小さくなると原波形のばたつきをノイズで吸収しなければならなくなる。また前提として，AR 成分を入れた場合は発散を防ぐため AR 係数の和は 1 未満でなくてはならない。これらに留意のうえ以降の計算を行った。

〈4･2〉 JEPX 価格系列における適用結果　前節までモデルがほぼ期待された推定をすることを確認したので，モデル①②を第 2 章で説明した JEPX 価格データに適用した。

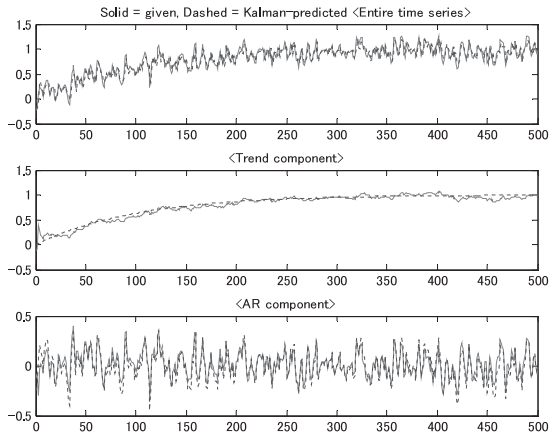

破線：真のデータ，実線：推定されたデータ
グラフ上から：時系列 P_n と推定結果，抽出されたトレンド成分，抽出された AR 成分
各パラメータは本文および表 1 による

図 3　モデル①のチェック（波形）
Fig. 3.　Validity check on Model 1.

表 1　モデル①のチェック（係数推定）
Table 1.　Validity check (coefficient estimation) for Model 1.

Parameter	True value	Estimated value
α_1	0.90	0.9685
α_2	-0.40	-0.4054
α_3	0.00	-0.0131
τ_1	total: 0.1	0.0121
τ_2		0.0585
σ_ε		(small enough number)

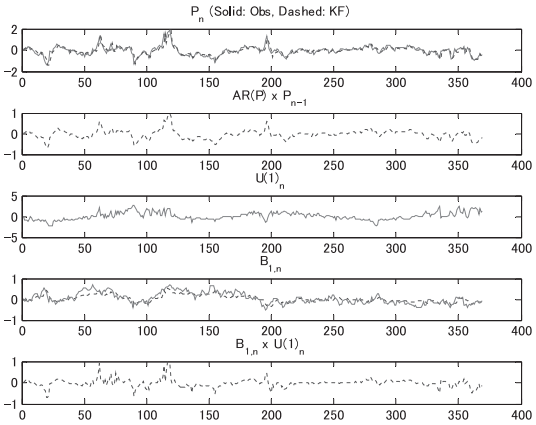

実線：真のデータ，破線：推定されたデータ
グラフ上から：時系列 P_n と推定結果，抽出された自己 AR^P 成分，外生入力 $U_{1,n}$，その係数 $B_{1,n}$，$B_{1,n} \times U_{1,n}$
各パラメータは本文および表 2 中「Case II」による

図 4　モデル②のチェック（波形）
Fig. 4.　Validity check on Model 2.

表 2　モデル②のチェック（係数推定）
Table 2.　Validity check (coefficient estimation) for Model 2.

Parameter	Case I		Case II		Case III	
	true value	estimated	true value	estimated	true value	estimated
AR^P	0.0000	-0.1750	0.5000	0.5212	0.8500	0.8443
σ_{B1}	0.1000	0.0682	0.1000	0.1353	0.2000	0.2748

表 3　モデル①における種々のトレンド次数 k，AR 次数 l に対する AIC

Table 3.　AIC on various trend and AR orders, Model 1.

l (AR) / k (Trend)	1	2	3	4
1	4.4638	**4.4512**	4.4566	4.4606
2	5.0713	4.5461	4.5700	*
3	*	*	*	*

(表内*：意味ある結果が得られず)

表 4　モデル①における種々のトレンド次数 k，AR 次数 l に対する対数尤度 LLH

Table 4.　LLH on various trend and AR orders, Model 1.

l (AR) / k (Trend)	1	2	3	4
1	-821.5694	-818.2405	**-818.2402**	-817.9877
2	-932.6457	-834.7571	-838.1637	*
3	*	*	*	*

(表内*：意味ある結果が得られず)

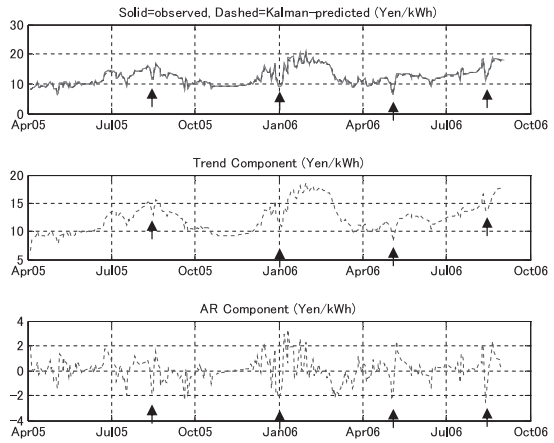

実線：真のデータ，破線：推定されたデータ

グラフ上から：時系列 P_n と推定結果，抽出されたトレンド成分，AR 成分

トレンド次数 $k = 1$，AR 次数 $l = 2$ のケース

図 5　モデル①によるトレンド成分と AR 成分への分離例（波形）

Fig. 5.　Decomposition to trend and AR components by Model 1.

① モデル 1　　AIC を基に最適なトレンド次数 k，AR 次数 l を選択する。種々の k，l に関する AIC を表 3 に，LLH を表 4 に示す。表中，「*」とは AR 係数の和が 1 を超えたり，逆にゼロになったりなど今回の計算意図からして意味を成さないものを表している。同表をみると，$k = 1$，$l = 2$ のとき AIC 最小を得て，この状態が最適であることがわかる。LLH では $k = 1$，$l = 3$ のとき最適であるが，前者とその差が小さいことから，ここでは AIC とモデルの簡便さを優先して $k = 1$，$l = 2$ を採ることにする。

このときの推定波形を図 5，係数推定結果を表 5 に示す。図 5 中の矢印は左から 05 年お盆，06 年正月，06 年黄金週間，06 年お盆である。上グラフが実価格系列とカルマンフィルタによる推定系列，中グラフがトレンド成分の推定結果，下グラフが AR 成分の推定結果である。表は AR 成分各係数 α_1，α_2 と，トレンドおよび AR 成分それぞれのノイズ標準偏差 τ_1，τ_2 および観測ノイズ σ_ε である。

表 5　モデル①によるトレンド成分と AR 成分への分離例（係数推定）

Table 5.　Decomposition to trend and AR components by Model 1 (coefficient estimation).

Parameter	Estimates
α_1	0.5240
α_2	0.0924
τ_1 [¥/kWh]	0.3937
τ_2 [¥/kWh]	0.5029
σ_ε [¥/kWh]	(small enough number)
LLH	-818.241
AIC	4.4512

表 6　今回検討した説明変数群の概略

Table 6.　Selected independent variables and labels.

Independent variable	Variable label	
Buy bid volume [MWh]	$B_{1,n}$	KAI_TOUNYUU
Sell bid volume [MWh]	$B_{2,n}$	URI_TOUNYUU
Daily highest temperatures exceeding last year's average [deg]	$B_{3,n}$	MAXKAIRI_TOKYO
Daily lowest temperatures exceeding last year's average [deg]	$B_{4,n}$	MINKAIRI_TOKYO
Tokyo-area maximum electricity demand [MW]	$B_{5,n}$	SAIDAI_TOKY
Dependent variable	**Variable label**	
Price strip [Yen/ kWh]	PRICE_31	

図 5 の上グラフより，カルマンフィルタの一期先予測によって原波形が良好に再現されているのがわかる。次にトレンドおよび AR 各成分については，春秋季においてと夏冬季において明らかに異なる水準を示し，トレンド成分は前者でおおむね 10 円/kWh 程度，後者でそれより 5〜7 円/kWh 程度高めの傾向になっていること，また，AR 成分は各季ともお盆，正月などの特異日において最も大きな変動をし，そのときトレンド，AR 成分ともに 2 円/kWh 程度ずつ下がることがわかる。この例では，AR 成分による変動は，特異日を除けば季節によらずほぼ上下 2 円/kWh 程度であること，また短期的な構造変化という意味では，記録的な厳冬だった 05 年 12 月からの冬季において急にばたつきが増加し，それ以外の時季と違った挙動を示していることも了解される。なお，表 5 において $\alpha_1 + \alpha_2 < 1$ であることから AR 系列の非発散条件を満たしている。これ以外の特定要因，例えば原子力など大型主要電源の停止や連系線補修など個別要因と価格上下動との対応については，現段階ではかならずしも対応関係付きで理解できるわけではないものの，所期の非定常トレンド分離が行われ，特異日などの挙動変化を短期的構造変化として確実に捉えたことが確認できる。

② モデル 2　　モデル②の説明変数群 U_i については，あとで最小 2 乗法モデルとの比較を行うため，最小 2 乗法モデルと同じものに揃えた。最小 2 乗法モデルは〈補論〉に示したように Box-Jenkins 法 [9] の考え方に沿って事前に準備した。

表 6 に，その説明変数群を示す。この表中の変数が示す

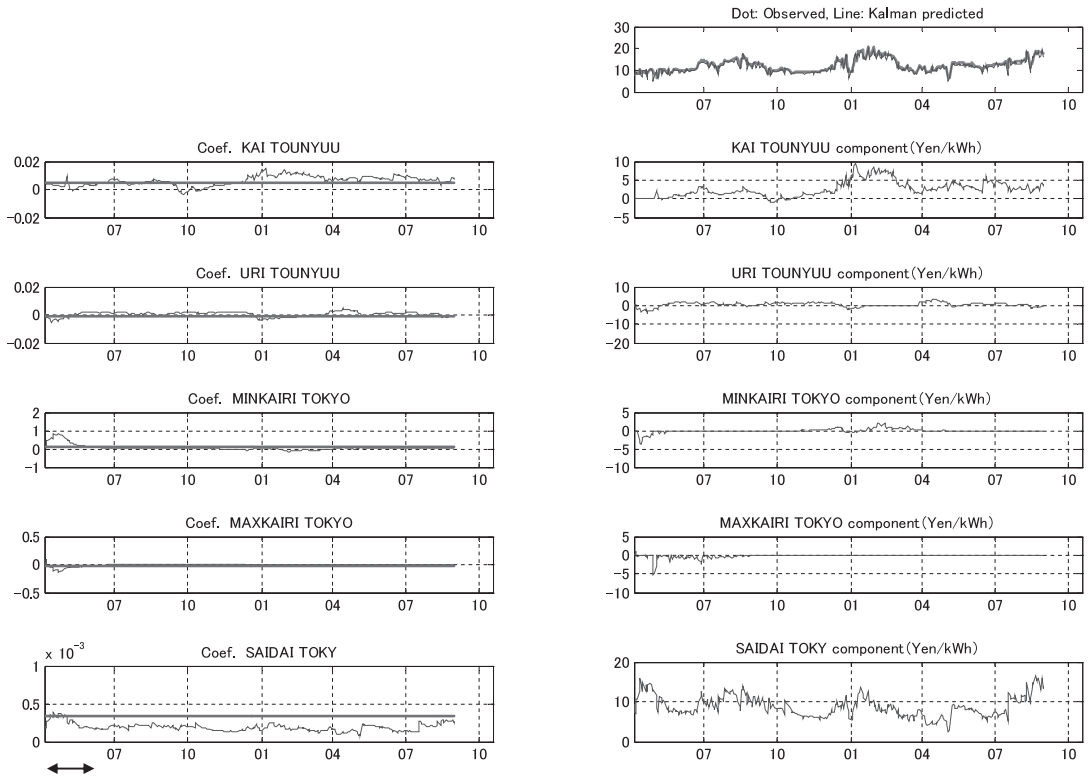

グラフ左列：上から各説明変数の係数推移（買い投入量，売り投入量，東京気温前年未満分，同超過分 [2]，東京地域最大電力（流通対応需要）
細線：本モデル，太直線：ARCH モデル（補論参照）における各推定係数
グラフ右列：上から価格（実値および推定値），それに対する各説明変数の寄与（左の各グラフに対応）

図 6　モデル②による時変係数の捕捉例（$AR^P = 0$，$AR^B = 0.953$ のケース）

Fig. 6.　Decomposition to independent variables by Model 2.

ものは上から買い投入総量，売り投入総量，東京の夏季最高気温前年平均超過分，同冬季最低気温前年平均未満分（負値），東京地域の最大電力（流通対応需要）である。これら説明変数の係数がなめらかな動きをすることを (11) 式で仮定したところであるが，AR_i^B については簡単のため $AR_1^B = AR_2^B \ldots = AR_5^B \equiv AR^B$ であるとし，試行した種々の値から AIC 最小化に基づき $AR^B = 0.953$ を用いた。また AR^P については今回は他説明変数群の時間変化に注意を払う目的から，これを除外（$AR^P = 0$）して計算した。

モデル②による推定結果を図 6 に示す。図の右半分は各説明変数の価格への寄与を示す。すなわち KAI_TOUNYUU 成分から SAIDAI_TOKY 成分まですべて足し合わせると一番上の価格系列が得られる。また，左半分の各グラフは，各説明変数係数の時間的な推移を示している。また ARCH モデルの係数水準との比較のため，太い水平線で ARCH モデルで得た各係数水準を併記してある。これらは定常性前提であるから期間全体にわたって定数である。

以下，同図の推定結果に従って，係数群の変化から見たそれぞれの変数の価格に対する影響度合いの推移について記す。今回推定した係数群の推移は，特に買い投入量（KAI_TOUNYUU）および売り投入量（URI_TOUNYUU）についておおむね ARCH モデル係数の前後で変動しているのがわかる。買い投入量については，同図の係数変化に見られるように，05 年 12 月から翌年 3 月程度にかけて，厳冬を反映して期間平均よりも高めになっていたこと，またその直前の 05 年 9～10 月程度は逆に低めになっていたことが了解される。一方，気温の平年超過値はいずれも（MINKAIRI_TOKYO，MAXKAIRI_TOKYO）係数がほとんどの期間で非常に小さく，05 年 12 月～06 年 3 月程度の冬季間に最大 2 円/kWh 程度の寄与があったほかは，価格に対してほとんど効いていないのがわかる。東京地域最大電力（流通対応需要）（SAIDAI_TOKY）は ARCH モデルの係数水準より全体的に小さく推移は安定しているが，価格に対する寄与の度合いはすべての変数のうちで最も大きく，最大電力自体の水準変動に呼応して 5～15 円/kWh 程度の範囲で変化している。また，すべての変数で 05 年 4 月の取引開始後 2 ヶ月間程度（図中左下ヨコ矢印）は市場自体の未成熟[†]を反映してか，それ以降とは違った動きをしているが，この部分は ARCH などの定常モデルでは先験的に捉えることのできない部分である。一方で，モデル②を用いて，説明変数係数の時変推移という形で取引構造の時間的な変化を捉えることができる点は有用である。

〈4･3〉 予　　測　時系列モデルには種々の活用方法

[†] 銘柄によっては約定にいたらず，例えば銘柄 4:00–4:30 は 05 年 6 月 22 日にいたるまで価格ゼロの日が数点存在した。

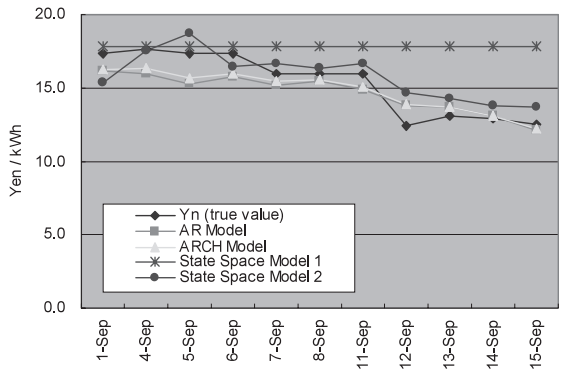

図 7　各モデルによる予測結果

Fig. 7.　Forecast result comparison.

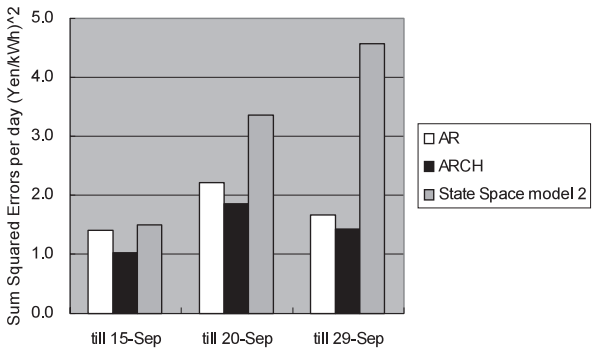

図 8　1 期当り誤差平方和 [yen/kWh]^2 でみた予測力比較

Fig. 8.　Forecast result comparison by sum squared errors.

があるが，代表的なものとして将来予測がある。〈4·2〉節までで構成したモデル①②に加え，補論に示した方法で得た AR，ARCH の各最小 2 乗法モデルも併せて将来価格予測を試み，予測力の評価を行って予測力向上のための方策について考える。

カルマンフィルタのアルゴリズムにおいて，実観測値 y_n が得られない将来期間においても，(3) 式［フィルタ］の第 2 式において状態 $x_{n|n}$ を更新することなく形式的に［一期先予測］を繰り返すことにより逐次的に二期以降先の将来予測を行える。これにより，2005 年 4 月～2006 年 8 月までの価格データに基づき 2006 年 9 月 1 日～9 月 29 日までの一括予測を行った。モデル②および最小 2 乗法モデルにおいては予測期間における各説明変数は実際のその期間の実現値を用いた。今回は，時間の経過に伴う予測力の低下の度合いも見るためモデル自身の諸設定値は〈4·2〉節で得た各設定値を維持したまま，更新することなく一括予測を行った。

予測結果を時系列で図 7 に示す。これをみると，モデル①（State Space Model 1）については価格自身の 2 期前までの情報（AR(2)）のみで決まるモデルであるため，2 期後（9 月 4 日）以降は急速に定数に収束しており，予測には向かないことがわかる。モデル②（State Space Model 2）と AR，ARCH の各最小 2 乗法モデルについては真値の動きに比較的よく追随している。

図 8 は予測力比較のため，予測期間全体（9 月 1 日～29 日）にわたる真値と予測値の誤差平方和を 1 日あたり平均値に直して比較したものである。横軸は，それぞれ 9 月 1 日～15 日まで，9 月 1 日～20 日まで，9 月 1 日～29 日までの 3 ケースにおける 1 日当りの平均誤差平方和であって，右に行くほど予測期間が長期になることを示している。なおモデル①は表示から外してある。これをみると，モデル②は 9 月 15 日までの期間では AR モデルと遜色ない予測パフォーマンスを示していることがわかる。また，全体的に AR モデルよりも，時変分散性を織り込んだ ARCH モデルのほうが誤差が小さくなっている。

予測期間の長期化に伴う誤差の増加傾向については，各モデルとも同様の傾向が見られるが，AR，ARCH モデルについて 9 月 20 日までのグラフがいったん高くなっているのは，9 月 18 日が月曜かつ祝日で，この日の周囲で誤差が高くなったことが主因である。したがって 9 月 29 日までの期間で見た場合には AR，ARCH モデルについてはその影響がふたたび平均化されて誤差は下がっている。しかしモデル②については一貫して増大しており，時間の経過と共に AR，ARCH モデルと比べて急速に誤差が増大傾向にあることを示している。この理由は，AR，ARCH モデルがそれまでの全期間（この場合 05 年 4 月～06 年 8 月）の平均的状態を基に 9 月の予測を行うのに対し，モデル②は 06 年 8 月末日一点の状態を基に 9 月の逐次予測を行うので，8 月末日の状態と平均的な状態との間にずれがあり，かつ 06 年 9 月の状況がそれ以前の平均的状況に近かった場合に AR，ARCH モデルに比べて不利になることが考えられる。モデル②についてはこの点を勘案して，〈4·2〉節で見たような市場構造の時変性を捉えながらも，予測においては期間の平均的特性を織り込めるようなモデルの開発が求められる。そのための手法について今後も検討の予定である。

予測力の向上策については最小 2 乗法モデル，状態空間モデルについて図 7，図 8 よりそれぞれ次のことが言えよう。最小 2 乗法モデルについては ARCH 項の考慮により時変分散性を織り込んで予測精度を上げることができた。状態空間モデルについては被予測系列自身の情報のみならず，説明変数を適切に選択し織込むことで，少なくとも短期においては最小 2 乗法モデルに遜色ない予測力を有することができた。

5.　まとめと今後の課題

状態空間モデルを用いて，JEPX スポット市場価格時系列の非定常トレンドと循環成分への分離，および取引構造の時変性表現ができるような 2 種類のモデリングを試みた。前者では先験的仮定なしにトレンドと AR 各成分へ分解され，特異日や季節に起因する変動を捉えた。後者では説明

変数係数群の時変性を捕捉することにより，各々の説明変数の寄与度が時間によって変動した構造変化を捉えると共に，予測力の面では少なくとも短期においてはAR，ARCHの各定常最小2乗法モデルと同等の予測力を得た。

なお，今回状態空間モデルと最小2乗法モデルとで予測性能の比較を行ったが，本来モデルの成り立ちからして，最小2乗法モデルが着目期間の平均的構造から将来の最良予測をしようとするのに対し，状態空間モデルは本稿にも示したように取引の構造変化を推定したり，成分抽出を行ったりできる点，また，カルマンフィルタアルゴリズムで逐次的な誤差修正を行い，時系列の変化に応じた動的な修正を行えるという点にある。今回は予測誤差のみを両モデルの比較の基準としたが，今後はこうした各モデルの着眼点の違いを考慮して，有用性の比較などを行いたいと考えている。

今後の課題として，海外電力市場データを用いた同様の検討による説明力の検証，状態空間モデルについては長期に亘って安定した予測力を与えるためのモデルの改良法について，引き続き検討を進める予定である。

（平成19年2月26日受付，平成19年5月24日再受付）

文　献

（1）「電気事業分科会制度改革評価小委員会報告書参考資料集」, http://www.enecho.meti.go.jp/denkihp/bunkakai/seidokaikaku_hyoka/index.html (2006)

（2）例えば，J. Lucia and E. Scwartz: “Electricity prices and power derivatives: Evidence from the Nordic Power Exchange”, *Rev. Derivatives Res.*, Vol.5, pp.5–50 (2002)

（3）H. Miyauchi, G. Tatsuguchi, and T. Misawa: “Regression Analysis of Electric Power Price in California Power Exchange”, *IEEJ Trans. PE*, Vol.124, No.2, pp.199–206 (2004-2) (in Japanese)
例えば，宮内　肇・竜口玄太・三澤哲也：「カリフォルニア電力市場価格の回帰分析」, 電学誌 B, **124**, 2, pp.199–206 (2004-2)

（4）Y. Itoh, Y. Murakami, and T. Kobayashi: “Time Series Analysis of Electricity Spot Price with AR-GARCH Model and its Application”, *IEEJ Trans. PE*, Vol.127, No.1, pp.61–68 (2007-1) (in Japanese)
伊藤保之・村上好樹・小林武則：「AR-GARCH モデルを用いた電力スポット価格の時系列分析とその応用」, 電学誌 B, **127**, 1, pp.61–68 (2007-2)

（5）G. Kitagawa and W. Gersch: “A smoothness priors-time varying AR coefficient modeling of nonstationary covariance time series”, *IEEE Trans. Automatic Control*, Vol.AC-30, No.1, pp.48–56 (1985)

（6）例えば，谷崎久志：状態空間モデルの経済学への応用 (1993)

（7）JEPX ホームページ：http://www.jepx.org/

（8）赤池弘次・北川源四郎 編：時系列解析の実際 II (1995)

（9）例えば，W. ヴァンデール（蓑谷千凰彦，他訳）：時系列入門 (1988)

付　録

〈補論〉最小2乗法モデルの作成

状態空間モデル②と説明変数の係数水準，および予測力を比較するための最小2乗法モデルを，以下の方法で作成した。

まず，第2章で説明したデータを用いて，図2でみた強い自己相関に伴う単位根の存在を検定するため単位根検定（Unit Root Test）を行った。定数項ありの条件で検定すると，ADF（Augmented Dickey-Fuller）検定およびPP（Phillips and Perrong）検定の結果いずれにおいても単位根ありの帰無仮説が棄却されたので単位根なしとして，階差処理などを行わずに以降の処理を進めた。

説明変数としては一般的に入手可能な種々の変数から，事前検討の結果本文表6に掲げたものを用いた。表中，気温については最高，最低共に2乗の項までを考慮した。また，実務上の観点からは，価格に対してそれより前の日付で得られる情報（ラグ（lag）情報と呼ぶ）のみを用いないと意味がない，といった考え方もあると思われたので，同表の変数群についてはラグ情報のみ（価格に対して2期前までを考慮後最適なものを選択）を用いた。予測では，これと同じ値をモデル②に対しても用いた。これら線形説明変数群と自己相関（AR）項，移動平均（MA）項，自己回帰条件付分散（GARCH）項までを考慮し，対数尤度最大化を満たすような定式化および次数選択を行った，

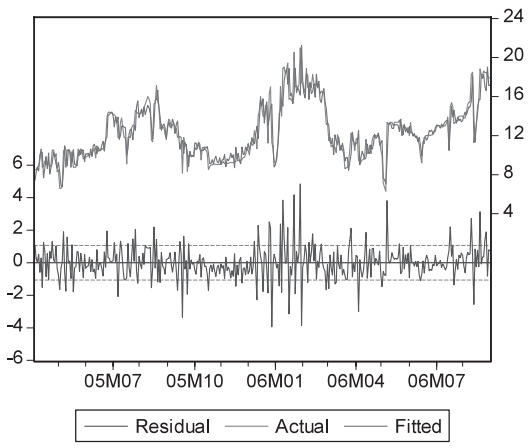

付図1　ARCHモデルの当てはまりと残差

app. Fig. 1.　Residual, Actual and Fitted plots of ARCH model.

付表1　AR，ARCHの各最小2乗法モデル推定結果の概略

app. Table 1.　Estimation results of ARMA and AR-ARCH models.

	Variable	C	YAKUJOU_RYOU	KAI_TOUNYUU	URI_TOUNYUU	MINKAIRI_TOKYO	MAXKAIRI_TOKYO^2	SAIDAI_TOKY	AR(1)	Adj.R Sq.	LLH	D.W.
AR model	Coefficient	-2.9280 **	-0.00185 *	0.0049 ***	-0.00123 ***	0.10380 **	-0.01897 ***	0.000339 ***	0.8180 ***	0.8643	-536.336	2.23
	t-Statistic	-2.0560	-1.7585	4.4936	-2.6356	2.5309	-8.5250	11.9498	26.2093			
ARCH model	Coefficient	-3.4313 ***		0.0049 ***	-0.00089 **	0.08741 ***	-0.01810 ***	0.000335 ***	0.8484 ***	0.8613	-531.645	2.31
	t-Statistic	-2.6786		5.6507	-1.9866	2.6354	-11.1066	14.9934	25.7143			
		variance const.	variance coef.									
Variance Equation	Coefficient	0.9044 ***	0.1785	Adj.R.Sq.= Adjusted R Squared, LLH = Log Likelihood, SSE = Sum of squared errors								
	z-Statistic	16.1527 ***	2.9677	D.W.=Durbin Watson Statistic								

Note:　Confidence bounds　90%(*),　95%(**), 99%(***)

次に係数推定を行い，90%水準で非有意な変数を落として，その状態での残差が分散不均一，系列相関をもたないことを各種の検定にて確認し，結局下記2種類のモデルを得た。

（1） ARモデル：約定量（YAKUJOU_RYOU），買い投入量（KAI_TOUNYUU），売り投入量（URI_TOUNYUU），最低気温（MINKAIRI_TOKYO），最高気温2乗（MAXKAIRI_TOKYO^2），東京地区最大電力（SAIDAI_TOKY），1次自己回帰（AR(2)）。

（2） ARCHモデル：買い投入量，売り投入量，最低気温，最高気温2乗，東京地区最大電力，AR(1)，ARCH(2)。

このうちARCHモデルの当てはまりの様子を付図1に示す。同図によると時折，残差（Residual）が統計的に有意な線（左スケールの±1前後の点線）を越えており，本モデルで説明できない部分であるが，ここでは状態空間モデルとの比較が主眼であるため，続きの処理は割愛した。

大　藤　建　太（正員） 1972年2月23日生。1996年3月東北大学大学院工学研究科博士前期課程修了。東北電力（株）等を経て，2006年6月より（財）電力中央研究所社会経済研究所事業経営・電力政策領域協力研究員。2004年4月より会津大学大学院コンピュータ理工学研究科博士後期課程在学中。1996年日本応用磁気学会武井賞受賞。エネルギー・資源学会，公益事業学会会員。

兼　本　　茂（非会員） 1951年7月5日生。1976年3月大阪大学工学部修士課程修了。現在，会津大学コンピュータ理工学部教授。（株）東芝原子力研究所で，原子力プラントの監視・診断システムの研究開発，時系列データ解析，システム同定などの研究に従事。2005年10月から現職。工博。原子力学会，計測自動制御学会，日本保全学会などの会員。