****
研究論文
****

スパースモデルを用いた JEPX スポット市場価格の予測および要因分析

Sparse Modeling Approach for Day-Ahead Electricity Price Forecast and Factor Analysis in the Japanese Spot Market

金 子 奈 々 恵 *・ 井 上 智 弘 **
Nanae Kaneko　　Tomohiro Inoue

（原稿受付日 2021 年 11 月 30 日，受理日 2023 年 6 月 20 日）

Abstract
Forecasting electricity prices plays a key role for stakeholders to construct an electricity business strategy. In recent years, electricity power system structures have undergone changes because of the large-scale penetration of renewable energy sources and the change in consumer behavior. These system changes have led to increased uncertainty in the behavior of electricity prices. This behavior is also influenced by various other factors such as past prices, weather, and consumer lifestyle. This research focuses on the day-ahead forecasting of the most recent electricity spot market prices in the Japan Electric Power Exchange, and proposes an approach to identify the effects of important factors on the dynamic characteristics of the market prices by constructing sparse models. The concept of the sparse modeling is an attractive approach to identify the effects of variables mechanically based on the coefficients in constructed models. Additionally, the proposed approach selects variables of particular importance based on statistical testing using the coefficients. The proposed scheme was applied to a real-world price dataset and discussed in the context of representation errors and interpretability. The results show that the proposed scheme is an effective approach for representing the impact of variables on electricity market price.
Keywords : Electricity price forecast, Factor analysis, Japan Electric Power Exchange, Spot market, Machine learning

１．はじめに

1990 年以降の世界的な電力市場の自由化に伴い，電力市場価格予測は，電気事業者の意思決定において重要な役割を担ってきた．しかし，近年の再生可能エネルギーの大量導入や消費者の行動変容等により電力市場価格を左右する要因が多様化しつつある状況下で，電力市場価格の予測は困難な状況にある．このような状況下で電力市場価格に与える要因とその影響を理解し，価格予測精度を向上することは，電気事業者が意思決定を行う上で解決すべき重要な課題となっている．

従来，電力市場価格の短期先予測については様々なアプローチが検討されてきた [1)2)]．例えば時系列手法（AR・ARIMA・GARCH）[1)]は，過去の電力市場価格の周期的なパターンを統計学的モデルを用いて記述する手法であり，市場価格予測をする上で比較的適切に機能してきた．一方で，近年の電力システムの変化に伴い，市場価格を左右する要因として過去の価格データに加えて観測可能な多数の変数を利用した研究が着目されつつあり [3)4)]，価格に影響を与える要因の多様化・複雑化が示されている [4)]．

本研究では，日本卸電力取引所（JEPX）のスポット市場価格の翌日予測に着目する．JEPX における電力の取引量は 2018 年後半より増加しているが [5)]，近年のスポット市場価格に着目した検討は観測サンプル数が限られていることなどから十分に行われていない．そこで我々は，従来検討されてきた種々の価格予測のためのアイデアを導入した統計モデルの構築枠組みについて，2020 年 4 月～2021 年 10 月のスポット市場価格を予測した場合の予測精度を季節や価格状況別に評価することで，状況別に適した予測枠組みを明らかにする．さらに，価格に影響を与える要因の候補として 1000 を超える変数に着目し，実需給の前日 10 時の段階で得られるデータセットに Least Absolute Shrinkage and Selection Operator(Lasso)回帰 [6)]を適用して，日毎に翌日価格予測モデルを構築し，推定したモデルの回帰係数の大小を統計的検定により評価することで，市場価格に対する影響度が最も大きな変数を識別する．Lasso 回帰に基づく統計モデル構築は，多数の説明変数を有するデータセットに対して，目的変数に影響を与えうる変数群のうち影響度の高い変数を機械的に識別可能である点から，近年の機械学習の文脈で広く利用されている．本研究は，このような検定に基づく要因解析を年月別・市場価格帯別にそれぞれ実施することで対象期間中の各状況下における影響度の大きな変数とその影響の特徴の違いを明らかにする．

本論文は以下の構成に従う．2 章では，本研究にて対象とするスポット市場価格について近年の価格傾向の事前解析を行った上で本研究の問題設定をまとめる．3 章では，

Corresponding author; Nanae Kaneko, E-mail: n.kaneko@aoni.waseda.jp
*早稲田大学　先進理工学部　電気・情報生命工学科
〒169-8555 東京都新宿区大久保 3-4-1
**一般財団法人　電力中央研究所　社会経済研究所
〒100-8126 東京都千代田区大手町 1-6-1 大手町ビル 7 階

第 38 回エネルギーシステム・経済・環境コンファレンスの内容をもとに作成されたもの.

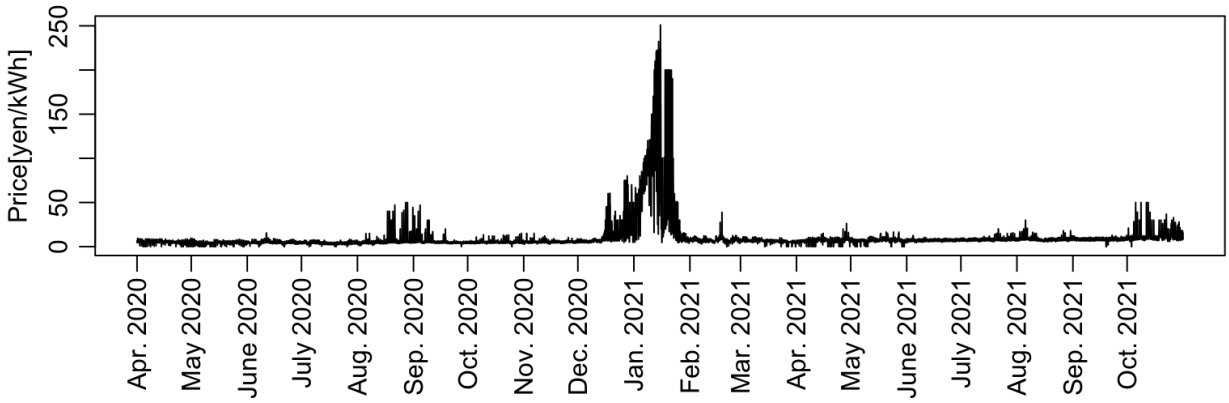

図 1　スポット市場価格の推移

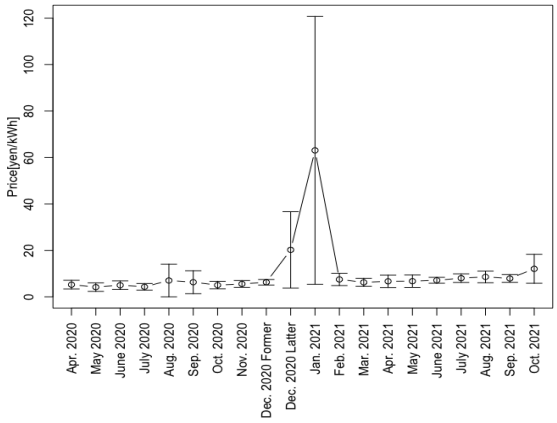

図 2　月別の市場価格の平均
(注) Dec. 2020 Former と Latter はそれぞれ 2020 年 12 月 1 日～14 日と 15 日～31 日の期間を示す．エラーバーは標準偏差を示す．

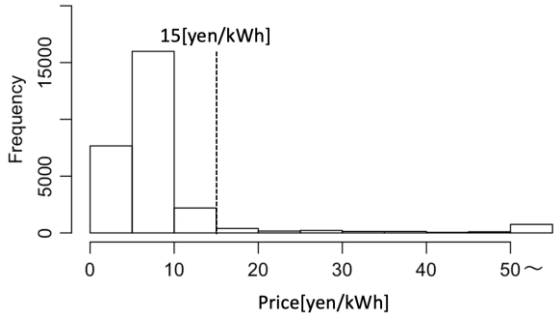

図 3　市場価格の水準と発生の頻度

本研究で採用するスパースモデルに基づく電力市場価格予測の枠組みを説明する．4 章では，電力市場価格および観測変数について実データを用いた解析と結果の考察を実施する．最後に 5 章では，本研究のまとめを行う．

２．スポット市場価格の推移

JEPX では，主に一日前市場（スポット市場）とその後の調整市場として当日市場(時間前市場)が開設されており，スポット市場では毎日 10 時に入札を締め切り，翌日に受渡する電気が取引される．本研究では，直近の電力市場価格の推移に着目するために，2020 年 4 月から 2021 年 10 月までのスポット市場のシステムプライス（以下，市場価格）を対象とした検討を実施する．本章では，市場価格の統計学的な特徴について解析を行う．

図 1 は 2020 年 4 月 1 日から 2021 年 10 月 31 日までの市場価格の推移を示す. スポット市場は, 1 日あたり 30 分毎, 48 断面に分割されており，最小値は 0.01[yen/kWh]の非負値である．**図 2** は，解析期間の各年月における市場価格の平均を示す. 図より 2020 年度冬期に価格が急激に高騰するタイミング（スパイク）が多く確認できる．また，2020 年の 8，9 月や 2021 年の 10 月も価格が高値傾向かつ分散が大きくなる期間が存在したことが確認できる．ここで，**図 3** に対象期間における価格の水準と発生の頻度の関係をヒストグラムを用いて表す. 結果より，市場価格は，主に 0～15 円の値を取る一方で 15 円以上の高値になるタイミングも存在することが確認できる．このようなスパイクは，局所的に市場価格が高騰することから電力会社等による意思決定において重要な指標となる．

電力スポット市場価格の短期先（数時間～数日先）予測としては，伝統的に統計学的なモデルに基づく種々のアプローチが検討されてきた．例えば，Uniejewski et al.[7]は価格推移の周期性に着目し，過去の市場価格データを用いた統計モデルの構築に基づく翌日の価格予測の枠組みを構築している．さらに彼らは，価格データに加えて曜日や平日休日情報を表すダミー変数や負荷予測データ等の価格を左右しうる変数を用いることで価格の周期性では説明のできない変動を外生変数を用いて表現する枠組みを提案している．森平 [3]は，日本の電力市場価格と気象情報の関係に着目した予測手法を提案している．このような過去の電力市場価格データと外生変数に着目したアプローチは，価格データの変動を説明する上で，比較的有効に機能することが確認されており，価格に影響を与える要因の選択は価格予測の問題において重要なタスクとなっている．特に，近年の電力市場価格の不確実性が高まる状況下において，観測・収集可能な多数の変数を利用した要因解析と価格予測精度の

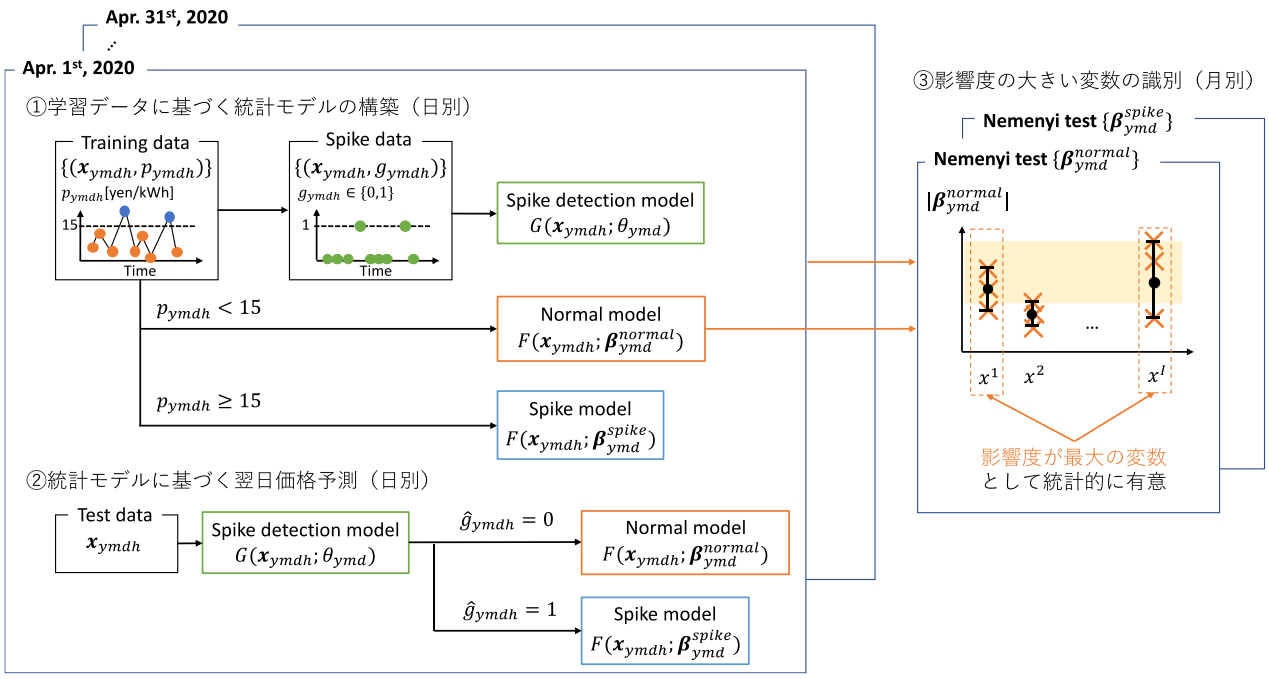

図 4　提案枠組みの概要

向上が期待されている．また，Omura et al.や大村他 [4)8)]は，スパイクが発生する断面/通常時それぞれについて異なる統計モデルを構築することで市場価格の予測精度が向上することを確認している．さらに，市場価格の推移やスパイクの発生頻度には日単位や週単位のような短期的な周期性に加えて,春夏秋冬のような長周期的な季節性も存在することが確認されている [7)]．以上のような研究は，予測対象とする価格断面の季節やスパイクの発生状況に応じて，価格を左右する要因は変化することを示唆している．

本研究では，直近の 2020 年 4 月から 2021 年 10 月の市場価格に着目し，翌日の市場価格の予測を実施する．我々は，過去の価格推移のデータに加えて，スポット市場の入札締め切り時間である受渡日前日 10 時の段階で得られる曜日，時間情報，各エリアの主要地点の気象予報，発電所の稼働計画情報を価格を左右しうる要因の候補として用意し，多数の変数を用いた統計モデルの構築枠組みを検討する．ここで本研究では，翌日の各予測対象断面についてスパイクの発生状況(通常/スパイク)を予測した上で，スパースモデルに基づき価格予測を行う 2 段階の予測モデルを採用する．スパースモデルは，多数の説明変数を含むデータセットを扱う問題において, 個々の変数の貢献度に着目し，重要な変数を機械的に選択しながら統計モデルを構築できるという点で近年機械学習の分野で着目されている [6)7)9)]．これらの種々の市場価格の予測枠組みについて，季節や価格状況別に応じた予測結果の違いを定量的に明らかにする．さらに本研究では，スパイクの発生状況別に市場価格予測モデルを構築することで，日別およびスパイク発生状況別に各変数が市場価格に与える影響を明らかにする．日別・スパイク状況別に構築された統計モデルにおいて，各変数に対して推定された回帰係数の大小を年月別に比較評価することで,市場価格に与える影響度が高い変数を状況別に明らかにし，その違いを解析する．

3．統計モデルに基づく電力市場価格の翌日予測

本研究では, 電力受渡日前日 10 時の段階で得られる変数を用いて，翌日 0:00～23:30 の全 48 断面について市場価格を予測する枠組みに着目する．ここで，**図 4** に本研究で提案する価格予測の枠組みの概要を示す．①学習フェーズでは，過去の観測データに基づき，スパイク発生状況を予測するスパイク判別モデル(Spike detection model)と, 価格を予測する価格予測モデルを作成する．ここで価格予測モデルとしては，通常時の価格を明示的に記述する通常モデル(Normal model)とスパイク時の価格を記述するスパイクモデル(Spike model)の 2 種類を作成する. ②予測フェーズは，学習フェーズで作成した 3 種の学習モデルに基づき，翌日の各予測対象断面についてスパイク判別と価格予測の 2 段階の予測を行う．第 1 段階では，各予測対象断面についてスパイク判別モデルを用いてスパイクの発生状況(通常/スパイク)を予測する．第 2 段階では，第 1 段階で判別されたスパイク発生状況に応じた価格予測モデルを利用することで，各対象断面についてスパイクの発生状況を考慮した価格予測を行う．③解析フェーズでは，日別に構築された統計モデルの回帰係数の絶対値の大小に着目することで，スパースモデルにおいて選択された変数のうち市場価格に与

える影響が最も大きい変数として統計的に有意なものを特定する．

3.1 eXtreme Gradient Boosting(XGB)に基づくスパイク判別モデル

ここで，y年m月d日時間断面hの電力市場価格をp_{ymdh}，要因候補となる説明変数を次元数Iを用いて$\boldsymbol{x}_{ymdh} = (x^1_{ymdh}, \dots, x^I_{ymdh})$と表す．また，$\boldsymbol{x}_{ymdh}$については事前に標準化を実施する．スパイクの判別基準を 15[yen/kWh]とすると，対象時間断面のスパイクの発生状況（通常/スパイク）g_{ymdh}は，以下のように記述できる．

$$g_{ymdh} = \begin{cases} 0 & \text{if } p_{ymdh} < 15 \\ 1 & \text{if } p_{ymdh} \geq 15 \end{cases} \tag{1}$$

本研究は，各予測対象日において，それぞれ異なる統計モデルを構築することを想定する．ここで，同一予測対象日における各時間断面は同じ予測モデルを用いる．y年m月d日におけるスパイク判別モデルのパラメータをθ_{ymd}とすると，対象日のスパイクの発生状況は，以下のように予測できる．

$$\hat{g}_{ymdh} \cong G(\boldsymbol{x}_{ymdh}; \theta_{ymd}) \tag{2}$$

ここで，スパイク判別モデルの構築手法としては従来，決定木や Random Forest 等の複数のアプローチが検討されてきたが，本研究では eXtreme Gradient Boosting (XGB) [4)10)]に基づく手法を採用する．XGB は勾配ブースティングに基づくアンサンブル学習の一つである．このような XGB の枠組みは，判別問題について高い精度が期待されている．

3.2 Lasso 回帰に基づく価格予測モデル

各予測対象日において，通常時およびスパイク発生時の価格予測モデルをそれぞれ作成する（各価格予測モデルについて同一対象日の各時間断面は同じ統計モデル）．ここで，予測対象日y年m月d日において利用可能な学習期間Tのうち，価格データについて通常時/スパイク時の価格が観測された断面を$T^z \subset T\ (z \in (normal, spike))$，各日における通常時/スパイク時の価格予測モデルのパラメータをそれぞれ$\boldsymbol{\beta}^z_{ymd} = (\beta^{z0}_{ymd}, \dots, \beta^{zI}_{ymd})\ (z \in (normal, spike))$とすると，電力市場価格と説明変数の関係は以下の価格予測モデル$F(\boldsymbol{x}_{ymdh}; \boldsymbol{\beta}^z_{ymd})$で記述できる．

$$\begin{aligned} p_{ymdh \in T^z} &\cong F(\boldsymbol{x}_{ymdh}; \boldsymbol{\beta}^z_{ymd}) \\ &= \beta^{z0}_{ymd} + \textstyle\sum_j^I \beta^{zj}_{ymd} x^j_{ymdh} \end{aligned} \tag{3}$$

このような回帰モデルのパラメータ推定には一般的に最小二乗法が用いられる．しかし，説明変数の次元数Iが大きいとき，多重共線性 [11)]などによるモデルの不安定性が大きな問題となる．そこで本研究では，Lasso 回帰 を用いたモデルパラメータの推定手法を採用する．Lasso 回帰はスパースモデルの一種であり，正則化パラメータλによりパラメータ$\boldsymbol{\beta}^z_{ymd}$の大きさを縮小する手法である．ここで，Lasso 回帰を用いたパラメータ推定は以下のように記述できる．

$$\hat{\boldsymbol{\beta}}^z_{ymd} = \underset{\boldsymbol{\beta}^z_{ymd}}{\operatorname{argmin}} \left(\textstyle\sum_{y,m,d,h \in T^z} \left(p_{ymdh} - F(\boldsymbol{x}_{ymdh}; \boldsymbol{\beta}^z_{ymd}) \right)^2 + \lambda \sum_j^I |\beta^{zj}_{ymd}| \right) \tag{4}$$

Lasso 回帰に基づくモデル推定では，冗長な変数に関するパラメータβ^{zj}_{ymd}の大きさはゼロになる．このようなモデル推定の手続きにより，次元数の増加に伴う予測モデルの不安定性を解決するとともに，多数の変数の中から重要な変数を機械的に選択することを可能にする．

本研究では，上記の過程において推定されたスパイク状況$\hat{g}_{ymdh}$および$\hat{\boldsymbol{\beta}}^{spike}_{ymd}, \hat{\boldsymbol{\beta}}^{normal}_{ymd}$を用いて翌日の市場価格$\hat{p}_{ymdh}$を次式のように算出する．

$$\hat{p}_{ymdh} = \begin{cases} F(\boldsymbol{x}_{ymdh}; \hat{\boldsymbol{\beta}}^{normal}_{ymd}) & \text{if } \hat{g}_{ymdh} = 0 \\ F(\boldsymbol{x}_{ymdh}; \hat{\boldsymbol{\beta}}^{spike}_{ymd}) & \text{if } \hat{g}_{ymdh} = 1 \end{cases} \tag{5}$$

さらに，本研究では価格推移を学習するための最適な学習期間を評価するために，予測対象日の前数日の観測データのみを用いるモデル構築の枠組みを検討する．

3.3 Nemenyi テストに基づく重要な変数の識別

Lasso 回帰に基づく統計モデル構築は多数の説明変数を有するデータセットに対する頑健性と目的変数に影響を与えうる変数群のうち影響度の高い変数を機械的に識別可能である点から近年の機械学習の文脈で広く利用されている．各対象期間において構築した統計モデル$F(\boldsymbol{x}_{ymdh}; \boldsymbol{\beta}^g_{ymd})$の回帰係数$\boldsymbol{\beta}^g_{ymd}$の大きさは，各説明変数が価格予測に与える影響度を反映する．一方で，スパースモデルの枠組みにおいてモデルの回帰係数や変数の選択結果はデータセットの微小な変動に依存し，値が変動してしまう点が問題視されており [12)]，このような変数選択結果のブレは，市場価格に影響を与える重要な変数を明らかにする上で，解釈性を必要以上に悪化させる可能性がある．そこで，本研究は，Friedman-Nemenyi テスト [13)]に基づいて，年月毎に推定された回帰係数の絶対値$\{|\beta^{zj}_{ymd}|\}\ (j = 1, \dots, I)$を統計的に検定することで，市場価格に有意な影響を与える変数を明らかにする．

4．実データに基づくシミュレーション

4.1 シミュレーションの前提および評価方法

本章では 3 章で示した電力市場価格予測の枠組みについて実データを用いたシミュレーションを行う．我々は，価格に影響を与える要因の候補として，過去の市場価格，休日/平日情報を示すダミー変数，日本の代表的な地点における気象予報等の計 1484 個の説明変数に着目する（**表 1** に説明変数に関する詳細を示す．）．本研究では，2020 年 2 月 1

表 1　モデル構築に用いる説明変数

Index	Category		項目（次元数）
1	休日		平日/休日ダミー（1）
2-351	過去価格		過去 1 週間の市場価格（336），過去 1 週間の 1 日最小市場価格（7），過去 1 週間の 1 日最大市場価格（7）
352-379	曜日		曜日ダミー（7），曜日ダミー×前日の同断面価格（7），曜日ダミー×前日の最終断面価格（7），曜日ダミー×前日の 1 日平均価格（7）
380-427	月		月ダミー（12），月ダミー×前日の同断面価格（12），月ダミー×前日の最終断面価格（12），月ダミー×前日の 1 日平均価格（12）
428-619	時間		時間ダミー（48），時間ダミー×前日の同断面価格（48），時間ダミー×前日の最終断面価格（48），時間ダミー×前日の 1 日平均価格(48)
620-691	気温		全国 9 エリアの気温予報※（72）
692-763	気圧		全国 9 エリアの気圧予報※（72）
764-835	湿度		全国 9 エリアの湿度予報※（72）
836-907	雲量		全国 9 エリアの雲量予報※（72）
908-979	風速		全国 9 エリアの風速予報※（72）
980-1051	風角		全国 9 エリアの風角予報※（72）
1052-1123	降水		全国 9 エリアの降水予報※（72）
1124-1195	積雪		全国 9 エリアの積雪予報※（72）
1196-1483	天気		全国 9 エリアの天気予報ダミー:雨, 雪, 晴れ, 曇り※（288）
1484	発電		全国大発電計画出力(1)

(注) ※全国 9 エリアとは，北海道，宮城，富山，東京，愛知，大阪，広島，香川，福岡の代表地点を示す．各変数について 0:00, 3:00, 6:00, 9:00, 12:00, 15:00, 18:00, 21:00 を対象とした予報値を考慮する [15]．

表 2　検討モデル

モデル	スパイク判別モデル	学習期間
Lasso	—	2020/2/1~予測対象日前日
Lasso_spike	XGB	2020/2/1~予測対象日前日
Lasso_spike_X (X=40, 30, 14)	XGB	予測対象日前 X 日

表 3　予測結果の分類

	$g_t = 1$	$g_t = 0$
$\hat{g}_t = 1$	TP	FP
$\hat{g}_t = 0$	FN	TN

(注) ここで，TP は True Positive(真陽性)，TN は True Negative(真陰性)，FP は False Positive(偽陽性)，FN は False Negative(偽陰性)を示す．

日から 2021 年 10 月 31 日を市場価格および説明変数の収集期間とし，2020 年 4 月 1 日から 2021 年 10 月 31 日の各日を予測対象とする．また，各日における予測モデルは，対象日の前日 10 時までを学習期間として，それまでに観測可能なデータを利用し，モデルは毎日更新するものとする．**表 2** に本研究で比較検討を行う 5 種のモデルの概要を示す．モデル Lasso では，Lasso 回帰を用いた価格の直接予測を実施するモデルを構築する．ここで学習期間は，2020 年 2 月 1 日から予測対象日前日までとする．モデル Lasso_spike では，スパイク判別モデルを XGB，価格予測モデル(通常/スパイク)を Lasso 回帰に基づき構築する 2 段階予測を行う．また，学習期間はモデル Lasso と同様に 2020 年 2 月 1 日から予測対象日前日までとする．最後に，モデル Lasso_spike_X は，学習期間を対象日の前 X 日(X=40，30，14)として，2 段階予測を行う．また，正則化パラメータλは予測モデルごとに交差検証 [14]によって決定する．

本研究では，期間別に平均的な価格水準が大きく変化することの影響を考慮して，予測精度を以下の式で定義される Normalized Mean Absolute Error (Normalized MAE)に基づき評価する．

$$\text{Normalized MAE} = \frac{1}{N}\sum_{y,m,d,h}\frac{\left|\hat{p}_{ymdh} - p_{ymdh}\right|}{p_{ym}^{mean}} \quad (6)$$

ここで，p_{ym}^{mean}は，予測対象期間における各年月別の平均市場価格(**図 2** 参照)，Nは評価対象のサンプル数を示す．また，各対象日におけるスパイク判別結果を**表 3** のように分類したとき，スパイク判別の正解率は，以下の式で算出される．

$$\text{Accuracy}[\%] = \frac{\text{TP} + \text{TN}}{\text{TP} + \text{FN} + \text{FP} + \text{TN}} \times 100 \quad (7)$$

ここで，正解率は 0 から 100 の値をとり，大きくなるほど判別精度が高いことを示す．

4.2 モデルごとの予測精度の比較

図 5 は，予測対象となる 2020 年 4 月 1 日から 2021 年 10 月 31 日の全日を対象とした場合の各モデルの予測精度を示す．結果より，提案手法(スパイク判別に基づく 2 段階の

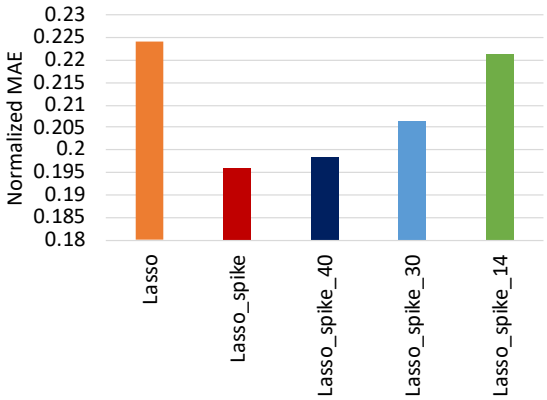

図 5　各検討モデルを用いた場合の予測精度（全日）

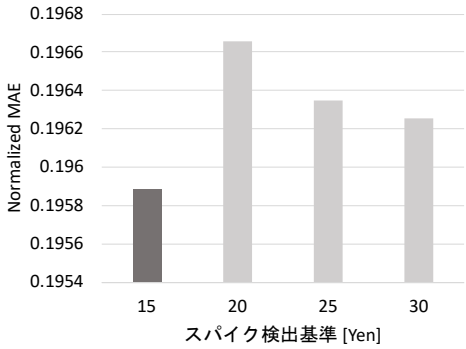

図 6　スパイク判別基準を変更した場合の予測精度（全日）

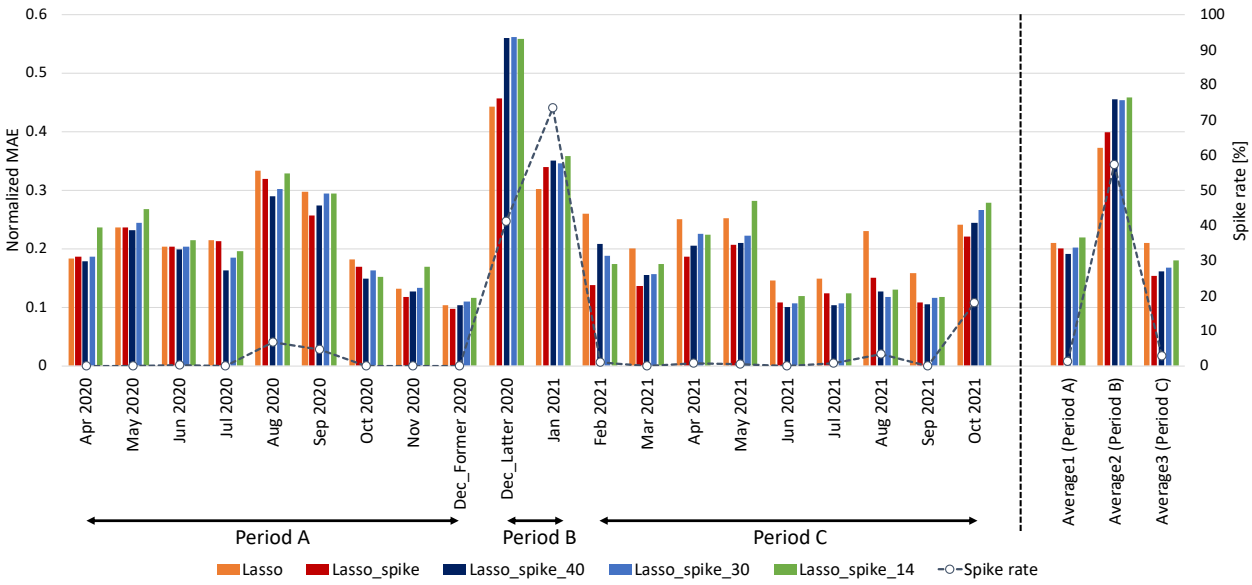

図 7　各検討モデルを用いた場合の年月別予測精度

(注) 点線は，年月別のスパイクの発生率を示す．

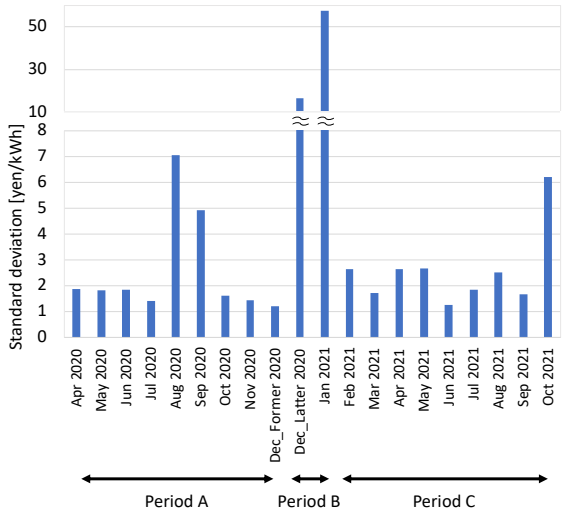

図 8　月別の市場価格の標準偏差

価格予測)によって，価格予測精度が向上することを確認した．また，**図 6** は，Lasso_spike モデルについて，スパイク判別基準を 15 円，20 円，25 円，30 円とした場合の予測精度を示す．結果より，判別基準を 15 円にすることで予測精度が向上することが確認できた．

図 7 に，各検討モデルについて，対象年月別の予測精度および各年月におけるスパイクの発生率を示す．平均値は 2020 年度冬期の価格高騰を考慮して，2020 年 4 月～12 月前半，2020 年 12 月後半～2021 年 1 月，2021 年 2 月～10 月のそれぞれの期間について算出される．**図 7** の結果より，スパイク判別に基づく 2 段階の価格予測を導入したモデル(Lasso_spike)は，異常な価格高騰期間(Period B)を除き，全期間を通して比較的高い精度を維持していることが確認できる．この結果は，スパイク判別に基づき，価格帯別の市場価格の挙動を明示的に学習する手法が，スパイク時/通常時共に良好に機能したことを示唆する．学習期間を限定したモデル(Lasso_spike_X)は，2020 年 12 月後半～2021 年 1 月における異常な価格高騰期間(Period B)ならびに 2021 年 2 月～5 月，10 月の期間において予測精度が悪化する傾向にあることが確認できた．ここで，**図 8** に予測対象期間における各年月の標準偏差を示す．図より 2021 年の 2 月～5 月および 10 月は，価格が高騰した期間(Period B)を除くと

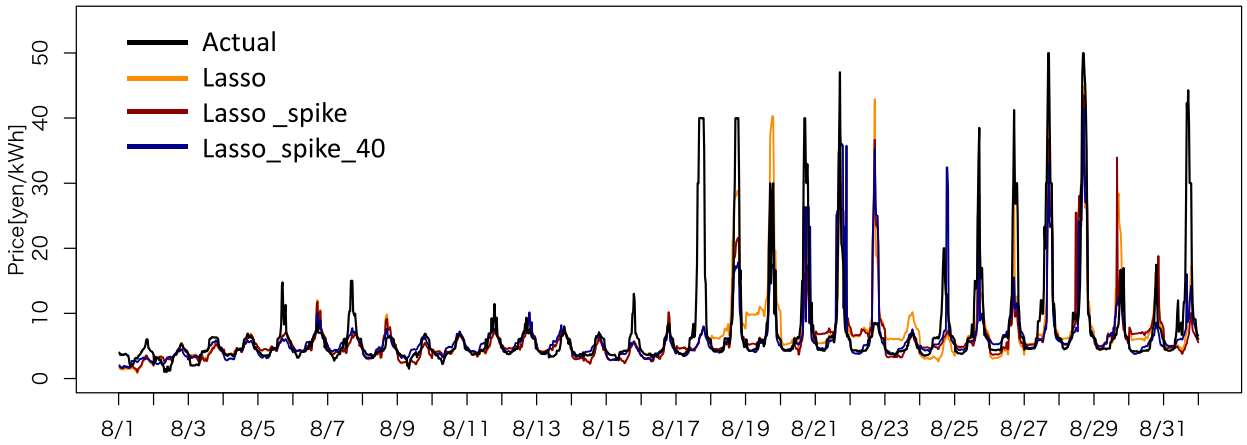

図 9　2020 年 8 月の市場価格予測について実測値と予測値の推移

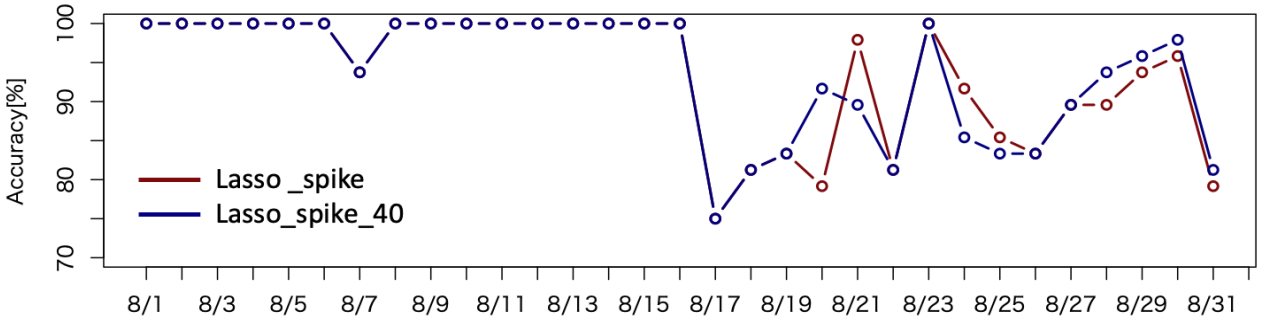

(a)　スパイク判別精度

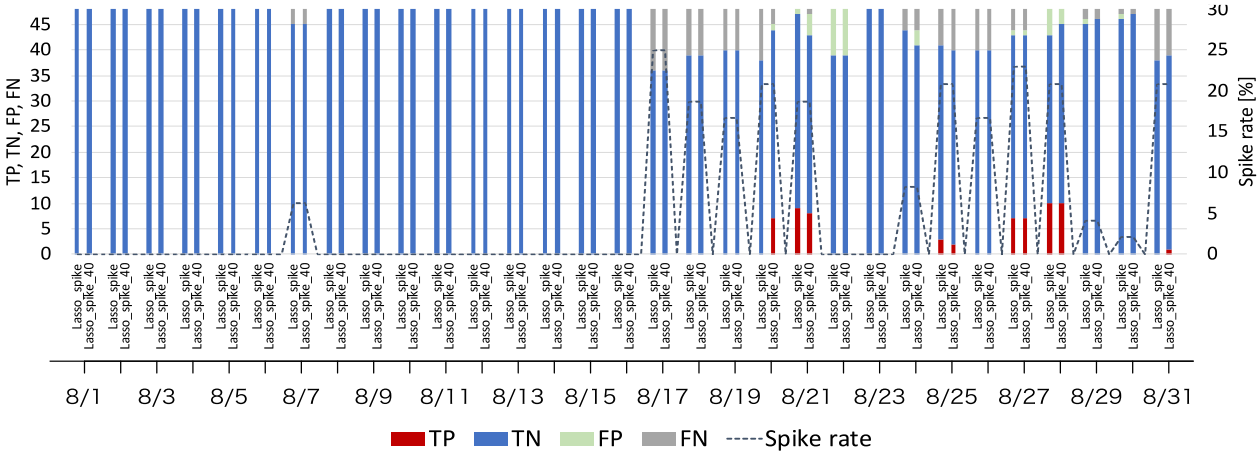

(b)　スパイク判別精度の詳細

(注) スパイク判別結果について**表 3** で示す各分類の頻度を示す.

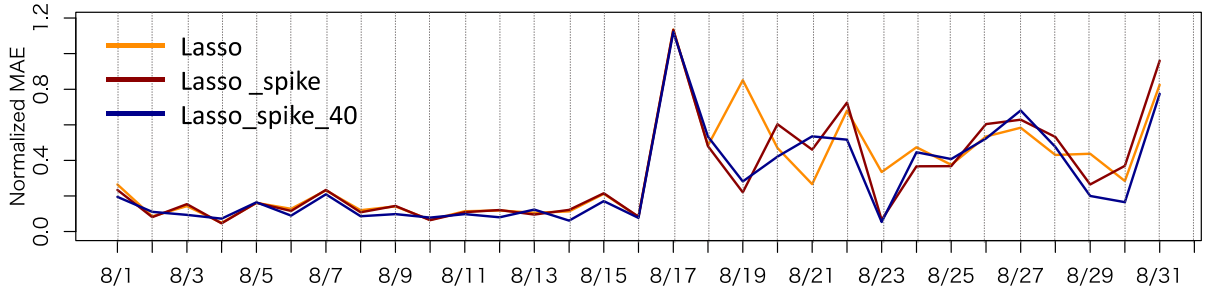

(c)　価格予測精度

図 10　2020 年 8 月の日別スパイク判別および価格予測精度

比較的価格変動が大きい期間であることが確認できる．一方で，2020 年 4 月～7 月や 2021 年 6 月，7 月等の価格が比較的安定に推移する期間においては，Lasso_spike_X モデルによる予測精度向上が確認できる．これは，市場価格の変動が安定的な状況下においては，予測期間直前の市場価格の挙動を明示的に学習する Lasso_spike_X モデルを用いることでより高い予測精度が期待できるのに対して，市場価格の挙動が不安定かつ，価格変動の特徴が直近の変動の特徴と大きく異なるような状況下では，Lasso_spike モデルを用いて長期的な期間に着目しながら，より多くの価格変動パターンを学習することで予測精度の向上が期待できることを示唆する．

ここで，2020 年 8 月の市場価格予測結果の推移に着目することで，各予測モデルの特徴を確認する．**図 9** に 2020 年 8 月の各予測対象日について Lasso，Lasso_spike および Lasso_spike_40 モデルを用いた場合の予測結果の推移を比較する．また，**図 10** に 8 月の各対象日について(a)スパイク判別の判別精度，(b)スパイク判別精度の詳細および(c)価格の予測精度を示す．ここで，**図 10**(b)スパイク判別精度の詳細は，**表 3** で示す予測結果の分類について，各分類の頻度を示し，TP および TN の頻度は，それぞれスパイクが発生した日におけるスパイク価格/通常価格のタイミング判別の精度を示唆する．結果より，2020 年 8 月について価格および Normalized MAE の推移を確認すると，スパイク判別を考慮したモデルにより，17 日以降のスパイクが頻出する期間において，Lasso 回帰モデルと比較して予測精度の悪化を軽減できていることが確認できる．ここで，**図 11** は，市場価格の実績が 1 円未満，1～15 円，15 円以上となる場合を対象とした価格帯別の各予測モデルの予測精度を示す．結果より，実績値が 1～15 円となる断面においてスパイク判別を考慮した市場価格予測による予測精度の向上が確認できる．さらに，学習期間を限定する枠組みによる予測精度の向上が確認できる．これは，予測対象日直近の通常時の価格を明示的に学習する枠組みが良好に機能したことを示す．実績値が 15 円以上となる断面に着目すると，スパイクが正しく判別された断面においてスパイク判別を考慮した市場価格予測による予測精度の向上が確認できる一方で，スパイクが正しく判別されなかった断面における予測精度の悪化が確認された．これらの結果は，スパイクの判別精度が価格高騰時の予測精度を大きく左右することを示唆する．

4.3 重要な説明変数の解析

最後に，各予測対象日について構築されたモデルにおける回帰係数の結果より，各年月の市場価格予測において市場価格に与える影響が特に大きい重要な変数について解析を行う．本報告では，平均的に予測精度の良かったモデル Lasso_spike に着目して重要な変数について考察を実施する．提案手法の枠組みは，年月毎に統計モデルの回帰係数に基づく Nemenyi テストを実施することで，市場価格に与える影響が最も大きい変数として有意なものを季節別に明らかにする(付録の図 A1 に 2020 年 8 月の通常時の価格予測モデル（全 31 モデル）に着目した場合の，各対象日のモデルの回帰係数と Nemenyi テストによって算出された重要な変数の例を示す．).

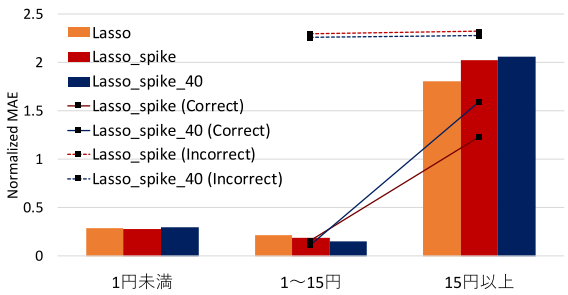

図 11　2020 年 8 月における価格帯別の予測精度
（注）ここで，Lasso_spike(Correct)/Lasso_spike_40(Correct)は，スパイクが正しく判別された断面，Lasso_spike(Incorrect)/Lasso_spike_40(Incorrect)は，スパイクが正しくされなかった断面の予測精度を示す．

図 12 に各年月において構築された統計モデルの回帰係数から Nemenyi テストを実施した場合の選択された変数とその回帰係数の符号をヒートマップを用いてまとめる．ここで，**図 12**(a)は通常時，(b)はスパイク時の結果を示す．結果より，全期間を通して選択される傾向にある変数群が存在する一方で，特定の期間のみ重要視される変数群が存在することが確認できる．また，通常時とスパイク時では重要視される変数が異なることが示唆される．ここで，Nemenyi テストにより選択された変数とその回帰係数の絶対値に着目しながら市場価格予測において影響度が高い変数を考察する．本研究では着目する多数の説明変数を複数のカテゴリー(カテゴリーの分類については**表 1** を参照)に分類しながら，選択変数の回帰係数(絶対値)のカテゴリー別平均値[1]を比較することで，通常時/スパイク時のモデル構築において大きな影響を与える変数群の特徴の違いを確認する．**図 13** は，(a)2020 年 4 月～12 月前半(Period A/価格高騰前)，(b)2020 年 12 月後半～2021 年 1 月(Period B/価格高騰中)，(c)2021 年 2 月～10 月(Period C/価格高騰後)の期間において,通常時/スパイク時の予測モデルについて，それぞれ Nemenyi テストにより選択された変数の回帰係数(絶対

[1] 本研究では，カテゴリー別の変数項目数の違いを考慮するために，回帰係数の平均値に着目する方法を採用する．

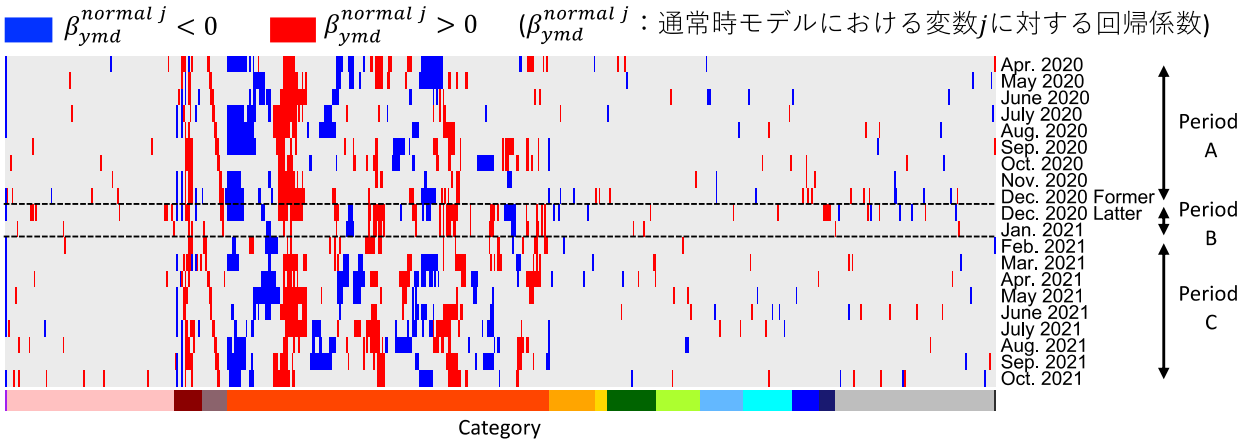

(a) 通常時

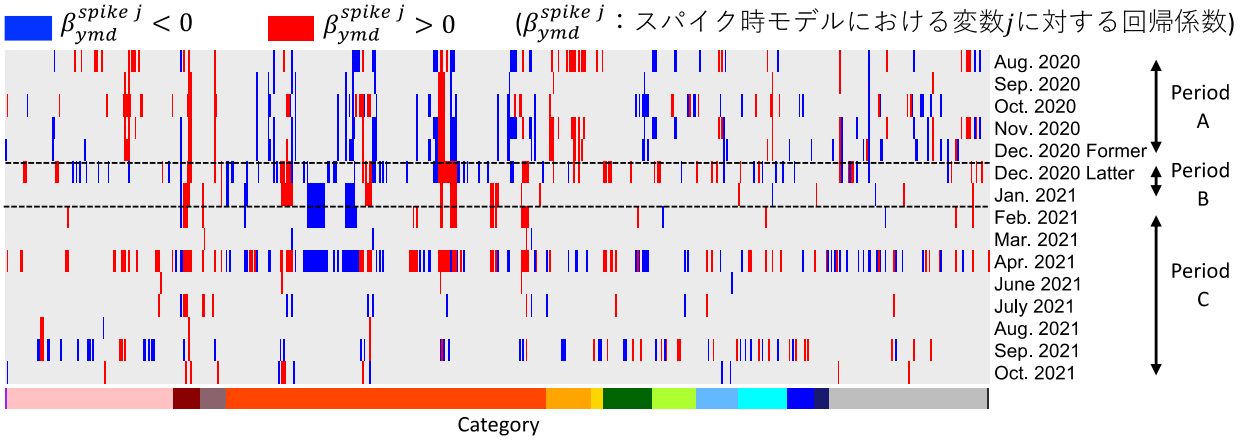

(b) スパイク時(予測モデルが構築された期間について)

図 12 影響度の高い説明変数
(注) Category ラベルの色は**表 1** の Category に対応する.

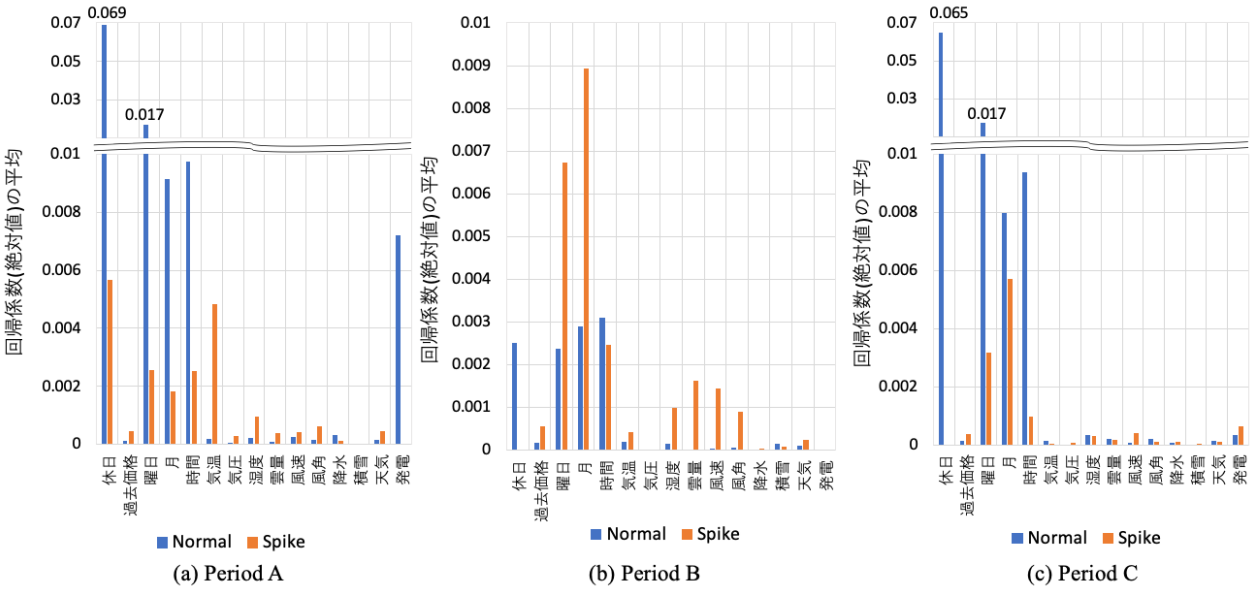

図 13 影響度の高い説明変数のカテゴリー
(注) Category ラベルは**表 1** の Category に対応する.

値)をカテゴリー別に平均した結果を示す. 結果より, Period A(2020 年 4 月～12 月前半)における，通常時とスパイク時の各変数の影響の大きさを比較すると，休日，曜日，月，時間情報の季節状況を説明する変数および降水や発電情報は，スパイク時と比較して通常時の影響度が相対的に高いことが確認できる．一方で, 過去価格や気温, 気圧, 湿度, 雲量, 風速, 風角, 天気情報の気象状況を説明する変数は, 通常時と比較してスパイク時の影響度が高いことが確認できた．Period B(2020 年 12 月後半～2021 年 1 月)の価格高騰中の期間に着目すると，休日，時間情報，積雪量の変数は通常時の影響が相対的に高い一方で，過去価格，曜日/月情報，気温，湿度，雲量，風速，風角，降水，天気の気象情報は, スパイク時の影響度が高いことが確認できる. また, Period C(2021 年 2 月～10 月)に着目すると, Period A と同様に休日，曜日，月，時間等の季節状況を説明する変数は, 通常時に影響度が高い事に加えて，気温，湿度，雲量，風角，天気情報の気象情報の影響度がスパイク時と比較して相対的に高いことが確認できる. 一方で, 過去価格, 風速, 降水や発電情報はスパイク時の影響度が高いことが確認できる．このような結果は，市場価格に影響を与える要因が着目する期間別および価格帯別に異なることを示し，日別の市場価格予測モデルの更新および価格帯別の予測モデルの構築は，各状況下においてこれら要因の違いを考慮する上で適切に機能したことを示唆する.

5. まとめ

本研究では，近年の日本のスポット市場価格に着目した電力市場価格の翌日予測および価格に影響を及ぼす変数について解析手法を提案した．我々は市場価格の翌日予測について，対象断面に対するスパイク発生状況の判別とスパイク発生状況を考慮した価格予測の 2 段階の予測モデルを提案した．また，構築された日別の通常時/スパイク時の統計モデルにおける回帰係数の大小に着目した検定手法を提案することで，年月別スパイク発生状況別に，価格に与える影響度の高い変数を明らかにした．さらに，検定に基づく提案手法より，年月別および通常時/スパイク発生時の価格予測において，重要視するべき価格を左右する要因をそれぞれ特定した.

結果より，スパイク発生状況を考慮した価格予測による予測精度の向上を確認した. また, 2020 年 4 月～7 月や 2021 年 6 月，7 月等の価格が比較的安定に推移した期間においては，学習期間を予測対象日直前の期間に限定した統計モデルにより予測精度の向上を確認できた．特に，スパイク発生状況を考慮した価格予測および予測対象日直前の期間に限定した統計モデルは，価格の実績値が 1～15 円となる価格帯において予測精度が向上する傾向にあるため，過去の電力市場価格の急激な変動等を事前に除いた学習データや統計モデルの構築は，通常時の価格予測に対して有効であると考えられる．一方で，価格の変動が大きい期間においては，長期的な学習期間に着目した統計モデル構築により，多くの価格変動パターンを学習する方法が有効に機能することが示唆された．また，通常時/スパイク時ともに曜日/月/時間を説明するダミー変数の影響が主要であることのほか，通常時と比べてスパイク時には，過去の価格や天気等の影響も重要であることが確認できており，価格への影響度の高い変数は年月別・スパイク発生状況別に変動することが確認された．このような結果は，状況別に異なる学習期間の長さや変数の影響を考慮しながら予測モデルの構築を行うことが市場価格の予測精度の向上において有効であることを示唆する.

本研究では，同期間の電力市場価格について複数の予測枠組みを適用することで，市場環境の違いによる各枠組みの精度の違いを確認した．今後は，これらの予測枠組みを市場環境の違いを機械的に識別しながら切り替える手法を導入することで予測精度の向上を目指す．また，我々は電力市場価格と説明変数の間に線形の関係を仮定し，線形モデルベースの予測モデルを採用した．一方で，近年観測される多数の説明変数の中には価格と非線形の関係を持つ変数も存在することが想定される．今後は，価格予測精度の向上を目指して非線形性を考慮した価格予測モデルの構築を行う．さらに，スパイク判別を考慮した予測枠組みに着目すると，翌日価格予測の精度について，スパイクが正確に判別できなかった断面における精度悪化が確認されているため，予測精度向上のためには，スパイク判別モデルの性能向上が有効であると考えられる．近年の電力市場価格はスパイクが発生する状況に加えて，価格が頻繁に 0.01[yen/kWh]と低値になるタイミングが存在する．価格が低値になるタイミングについてもスパイクと同様に判別を行うことで予測精度の向上が期待できる.

参考文献

1) A. A .Sánchez de la Nieta., V. González and J. Contreras; Portfolio decision of short-term electricity forecasted prices through stochastic programming. Energies, 9.12. 1069 (2016).
2) A. Ozozen, G. Kayakutlu, M. Ketterer and O. Kayalica; A combined seasonal ARIMA and ANN model for improved results in electricity spot price forecasting: Case study in Turkey. 2016 Portland International Conference on Management of Engineering and Technology (PICMET). IEEE, pp. 2681-2690 (2016).
3) 森平爽一郎; 気温オプションによる電力価格予測．リ

アルオプションと戦略, 11.1. pp. 35-45 (2020).

4) M. Omura, Y. Fujimoto, H. Ishii, Y. Hayashi, T. Sawa, H. Sasaki and N. Fukuyama; Day-ahead electricity price forecasting using an adaptive combination method in the Japanese spot market. 2020 17th International Conference on the European Energy Market (EEM). IEEE, pp. 1-6 (2020).

5) 経済産業省; https://www.emsc.meti.go.jp/activity/emsc_system/pdf/048_08_00.pdf (アクセス日 2021.11.28)

6) T. Robert; Regression shrinkage and selection via the lasso. Journal of the Royal Statistical Society: Series B (Methodological), 58.1. pp. 267-288 (1996).

7) B. Uniejewski and R. Weron; Efficient forecasting of electricity spot prices with expert and LASSO models. Energies, 11.8. 2039 (2018).

8) 大村愛花, 藤本悠, 林泰弘, 澤敏之, 佐々木浩人, 福山直人, 西野由高; オープンデータに基づく電力スポット市場のエリア価格予測. 電気学会論文誌 B (電力・エネルギー部門誌), 141.5. pp. 366-373 (2021).

9) N. Kaneko, Y. Fujimoto, S. Kabe, H. Fuchikami, T. Hattori and Y. Hayashi; Sparse modeling approach for identifying the dominant factors affecting situation-dependent hourly electricity demand. Applied Energy, 265. 114752 (2020).

10) T. Chen and C. Guestrin; Xgboost: A scalable tree boosting system. In: Proceedings of the 22nd acm sigkdd international conference on knowledge discovery and data mining, pp. 785-794 (2016).

11) A. Aylin; Multicollinearity. Wiley Interdisciplinary Reviews: Computational Statistics, 2.3. pp. 370-374 (2010).

12) S. Mullainathan and J. Spiess; Machine learning: an applied econometric approach. Econ Perspect, 31.2. pp.87-106 (2017).

13) E. Arias-Castro and S. Chen; Distribution-free multiple testing. Electron. J. Statist, 11.1. pp. 1983-2001 (2017).

14) R. Picard; Cross-validation of regression models. Journal of the American Statistical Association, 79.387. pp. 575-583 (1984).

15) Quick E-Power Polaris; https://corporate.quick.co.jp/biz/polaris/ (アクセス日 2023.6.6)

付録

図 A1 は，2020 年 8 月における価格予測モデル(通常時の予測モデル)において算出された回帰係数$\{\hat{\boldsymbol{\beta}}^{normal}_{2020,8,d}\}$の大きさおよび Nemenyi テストにおいて価格に与える影響が最も大きい変数として選択された変数を示す.

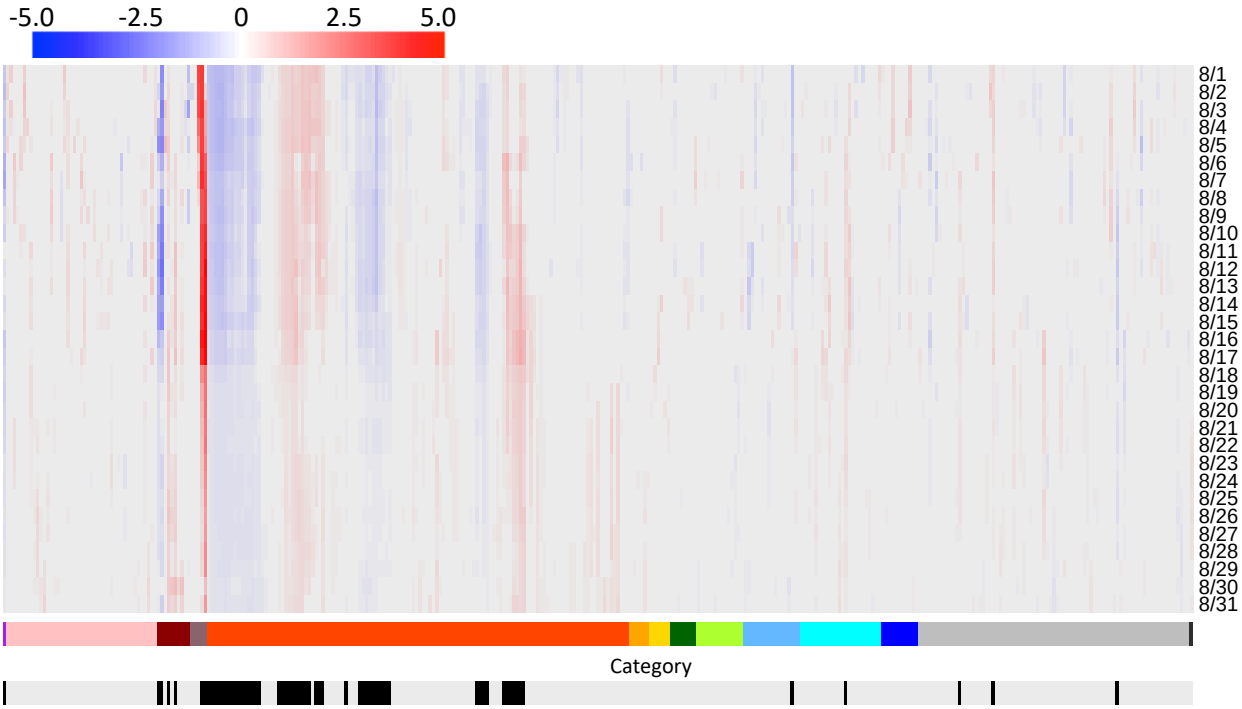

影響度が大きい変数（※Nemenyiテストで有意となった変数を黒で示している.）

図 A1　2020 年 8 月の通常時の予測モデルの回帰係数と影響度の高い説明変数